SII-GAIR

مستوى ذكاء المنفذ السلبي

هندسة السياق 2.0: سياق هندسة السياق

تشيشو هوا1,3 ليومانشان يي1,3 دايوان فو2,3 يانغ شياو2,3 شياو جيه كاي1,3

يونزي وو1,2,3 جيفان لين1,3 جونفي وانغ3 بنغفي ليو1,2,3,†

1SJTU 2SII 3GAIR

§ سياق جيشب SII

مستوى ذكاء المنفذ السلبي

" — المؤلفونالشخص هو مجموع سياقاته."

كتب كارل ماركس ذات مرة أن "الجوهر الإنساني هو مجموعة العلاقات الاجتماعية" (ماركس، 1845)، مما يشير إلى أن الأفراد ليسوا كيانات معزولة، ولكنهم يتشكلون بشكل أساسي من خلال تفاعلاتهم مع كيانات أخرى - حيث تلعب السياقات دورا تأسيسيا وأساسيا. ومع ظهور أجهزة الكمبيوتر والذكاء الاصطناعي، لم تعد هذه السياقات تقتصر على التفاعلات بين الإنسان والإنسان البحتة: بل أصبحت التفاعلات بين الإنسان والآلة متضمنة أيضا. ثم يبرز سؤال مركزي: كيف يمكن للآلات أن تفهم مواقفنا وأغراضنا بشكل أفضل؟ ولمواجهة هذا التحدي، قام الباحثون مؤخرا بتطوير" مفهوم هندسة السياق. على الرغم من أنه غالبا ما ينظر إليه على أنه ابتكار حديث في عصر الوكلاء، إلا أننا في الواقع نرى أن الممارسات ذات الصلة يمكن إرجاعها إلى ما يزيد عن 20 عاما مضت. منذ أوائل التسعينيات، تطورت عبر مراحل تاريخية متميزة، تشكلت كل منها حسب مستوى ذكاء الآلات: بدءا من أطر التفاعل بين الإنسان والحاسوب المبكرة المبنية حول أجهزة الكمبيوتر البدائية، إلى نماذج التفاعل بين الإنسان والوكيل اليوم التي يقودها عملاء أذكياء، وربما إلى المستوى البشري أو حتى الذكاء الخارق في المستقبل. في هذه الورقة، نناقش سياق هندسة السياق، ونقدم تعريفا منهجيا، ونحدد وجهة نظرنا حول مشهدها التاريخي والمفاهيمي، ونفحص اعتبارات التصميم الرئيسية لممارستها. من خلال معالجة هذه الأسئلة، نهدف إلى تقديم أساس مفاهيمي لهندسة السياق ورسم مستقبلها الواعد. تعد هذه الورقة بمثابة نقطة انطلاق لجهد مجتمعي

أوسع نحو هندسة السياق المنهجي في أنظمة الذكاء الاصطناعي. الملخص

أرخايف:30 [cs.AI] 2510.26493v1 أكتوبر 2025

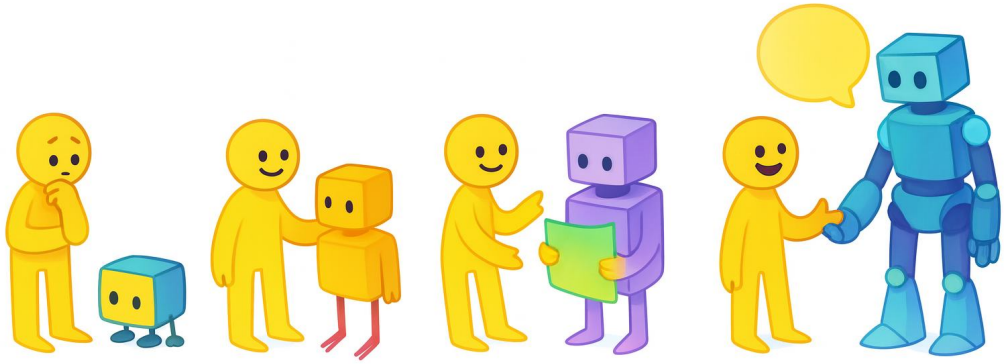

مستوى ذكاء المنفذ السلبي

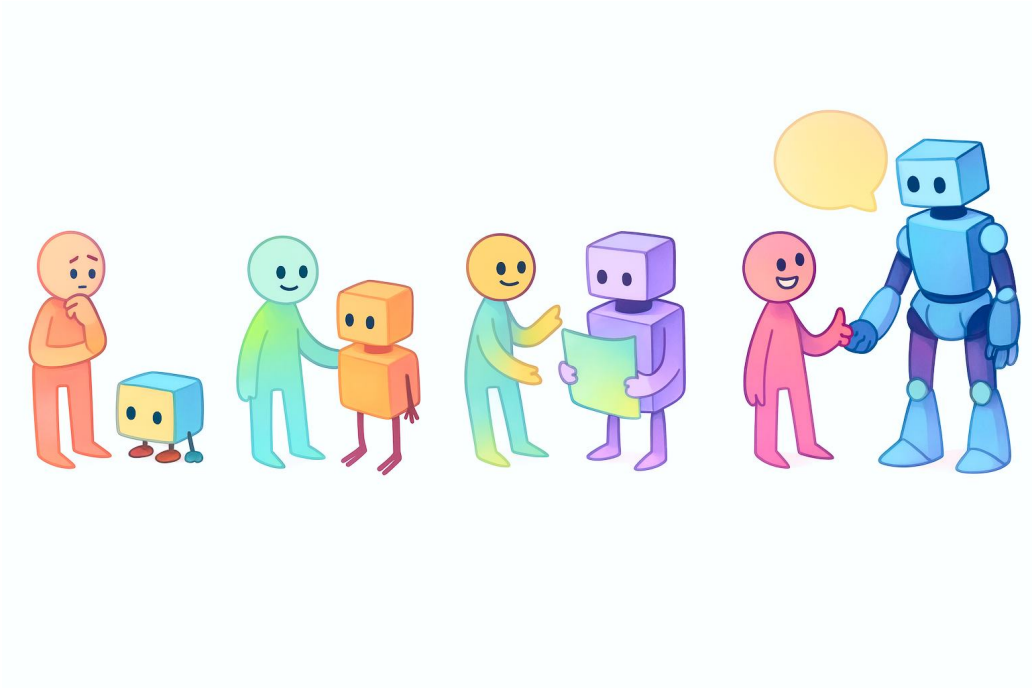

الذكاء. المزيد من القدرة على معالجة السياق. انخفاض تكلفة التفاعل بين الإنسان والذكاء الاصطناعي. المزيد من

السياق 1.0 السياق 2.0 السياق 3.0 السياق 4.0

نحن حاليا في عصر 2.0، وننتقل إلى عصر 3.0

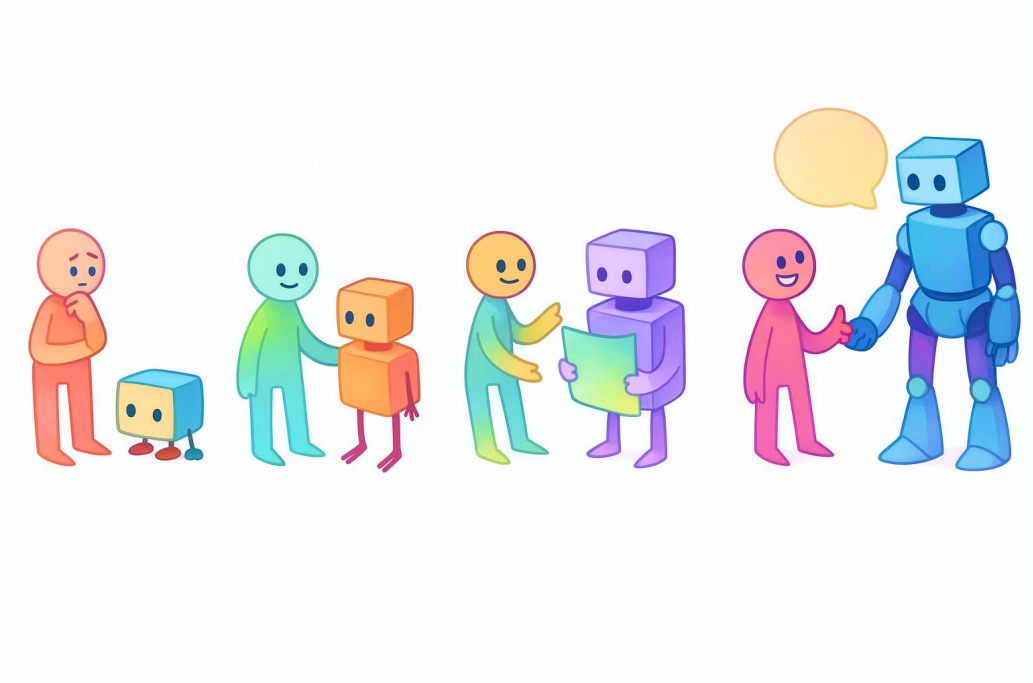

إدخال السياق

السياق كترجمة سياق كتعليمات سياق كسيناريو سياق كعالم

تكلفة التفاعل بين الإنسان والذكاء الاصطناعي

وكيل المبادرة متعاون موثوق به سيد محترم

الشكل 1: نظرة عامة على هندسة السياق 1.0 إلى هندسة السياق 4.0، مما يوضح أن المزيد من يؤدي إلى قدرة أكبر على معالجة السياق وانخفاض تكلفة التفاعل بين الإنسان والذكاء الاصطناعي. الذكاء

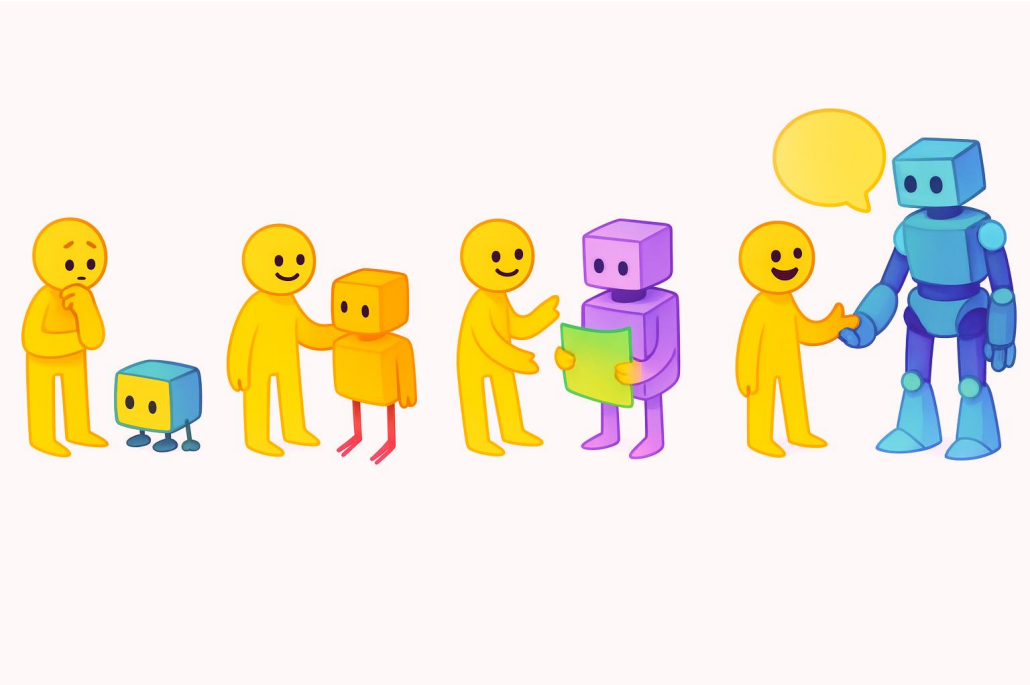

0† المؤلف المقابل.

المحتويات SII-GAIR

محتويات

1 المقدمة 32 الإطار النظري 4 2.1 التعريف الرسمي . . . . . .
. . . . . 4 2.2 توصيف المرحلة. . . . . .
. . . 6 3 التطور التاريخي 6 3.1 منذ أكثر من 20 عاما: العصر 1.0 . . . . . .
. . . . . 7 3.1.1 المشهد التكنولوجي. . . . . .
. . . . . 7 3.1.2 الأسس النظرية 7 3.1.3
الممارسات الأساسية. . . . . 7 3.2 بعد 20
عاما: العصر 2.0 . . . . . 8 4 تجميع السياق
وتخزينه 9 4.1 الاستراتيجيات النموذجية في العصر 1.0 و2.0. . . . . .
. . . . . 9 4.2 النظام البيئي للسياق على المستوى البشري. . . . . .

. . . . . 105 إدارة السياق 10 5.1 معالجة السياق النصي. . . . . .
. . . . . 10 5.2 معالجة السياق متعدد الوسائط. . . . . .
. . . . . 11 5.3 تنظيم السياق. . . . . .
12 5.3.1 بنية الذاكرة ذات الطبقات. . . . . 12 5.3.2 عزل
السياق . . . . . 12 5.4 تجريد السياق. . . . . .
. . . . . 13 6 استخدام السياق 14 6.1 مشاركة سياق
النظام داخل النظام. . . . . 14 6.2 مشاركة السياق
عبر الأنظمة. . . . . 15 6.3 اختيار السياق للفهم. . .
. . . . . 15 6.4 المستخدم الاستباقي يحتاج إلى استنتاج. . . .
. . . . . 17 6.5 الحفاظ على السياق وتحديثه مدى الحياة.
. . . . . 17 6.6 الممارسات الهندسية الناشئة. . . . . .
. . . . . 18 7 التطبيقات 19 7.1 CLI . . . . . .
. . . . . 19 7.2 البحث العميق. . . . . .
. . . . . 19 7.3 واجهات الدماغ والحاسوب. . . . . .
. 20

8 التحديات والتوجهات المستقبلية 20

9 الاستنتاج 21

---

1. مقدمة SII-GAIR

1 مقدمة في السنوات الأخيرة، أدى الارتفاع السريع لنماذج اللغة الكبيرة (LLM) والوكلاء الأذكياء إلى لفت الانتباه المتزايد إلى كيفية تأثير السياق على سلوك النموذج. أظهرت الدراسات أن المحتوى الموجود داخل نافذة السياق يمكن أن يؤثر بشكل كبير على أداء النموذج (Liu et al., 2021). وفي الوقت نفسه، هناك طلب متزايد على الأنظمة القادرة على التفكير متعدد الخطوات والعمل على مدى فترات زمنية طويلة (ياو وآخرون، 2023). تجعل هذه الاتجاهات سؤالا واحدا محوريا: كيف يمكننا تمكين الآلات من فهم النوايا البشرية والتصرف بناء عليها بشكل أفضل من خلال آليات سياقية فعالة، وخاصة في المهام طويلة المدى؟ ولمواجهة هذا التحدي، ركز الباحثون مؤخرا على هندسة السياق: ممارسة تصميم وتنظيم وإدارة المعلومات السياقية حتى تتمكن الآلات من التصرف بطرق تتوافق مع نوايا الإنسان (مي وآخرون، 2025). شهدت السنوات الأخيرة تطبيقات

واسعة النطاق لهندسة السياق في ماجستير إدارة الأعمال والوكلاء، بما في ذلك الهندسة الفورية (Liu et al., 2021; Reynolds and McDonell, 2021; Wei et al., 2022)، وتوليد الاسترجاع المعزز (RAG) (Lewis et al., 2020; Izacard and Grave, 2022)، واستدعاء الأدوات (Yao et al., 2022؛ داي2022؛ وو وآخرون، 2022؛ شيك وآخرون، 2023)، وآليات الذاكرة طويلة المدى (وآخرون، 2019). تعمل هذه التقنيات على توسيع قدرة الآلة على استيعاب السياق عالي الإنتروبيا، كما أثرت ماديا على تصميم الأنظمة التفاعلية. وعلى الرغم من هذه التطورات، كثيرا ما يساء فهم "السياق"هذا المجال. ينظر عادة إلى هندسة السياق على أنها تطور حديث، وغالبا ما يتم تعريف " بشكل ضيق على أنه تاريخ الحوار، أو مطالبات النظام، أو المدخلات البيئية التي تركز على الوكيل. في الواقع، يمكن تعريف السياق على نطاق أوسع، وقد تم ممارسة هندسة السياق لأكثر من 20 عاما. أدت الأبحاث المبكرة في مجال الحوسبة في كل مكان، والأنظمة المدركة للسياق، والتفاعل بين الإنسان والحاسوب إلى إنشاء مبادئ وأساليب أساسية لا تزال ذات صلة حتى اليوم (Reeves, 2012; Baldauf et al., 2007a; Preece et al., 1994). يعد التعرف على هذا التاريخ أمرا ضروريا لفهم الوضع الحالي للمجال وإمكاناته المستقبلية. نحن نرى أن تطوير هندسة السياق يجب أن ينظر إليه من خلال منظور تاريخي أوسع بدلا من أن يقتصر على الممارسات التقنية الحديثة. ومن خلال تتبع تطورها على مدى العقدين الماضيين، يمكننا اكتساب فهم أعمق لمبادئها الأساسية والتعرف على الكيفية التي ساهمت بها الأساليب المختلفة للتعامل مع السياق في تشكيل تقدم الأنظمة الذكية. يمكن هذا الرأي أبحاث الذكاء الاصطناعي من البناء على مسارها التاريخي، وإنشاء أساس قوي وموجه نحو المستقبل. Langchain كلود كود المؤشر Letta

GAIR

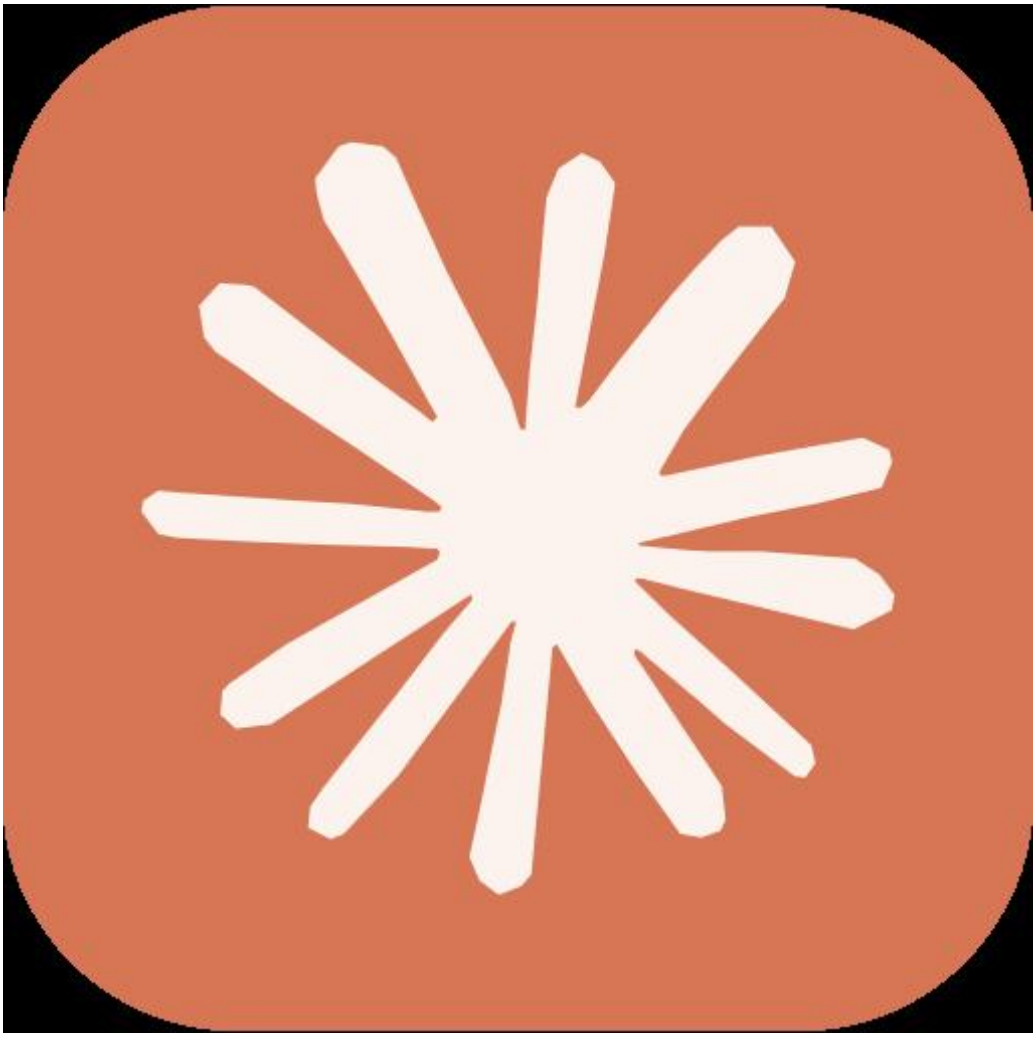

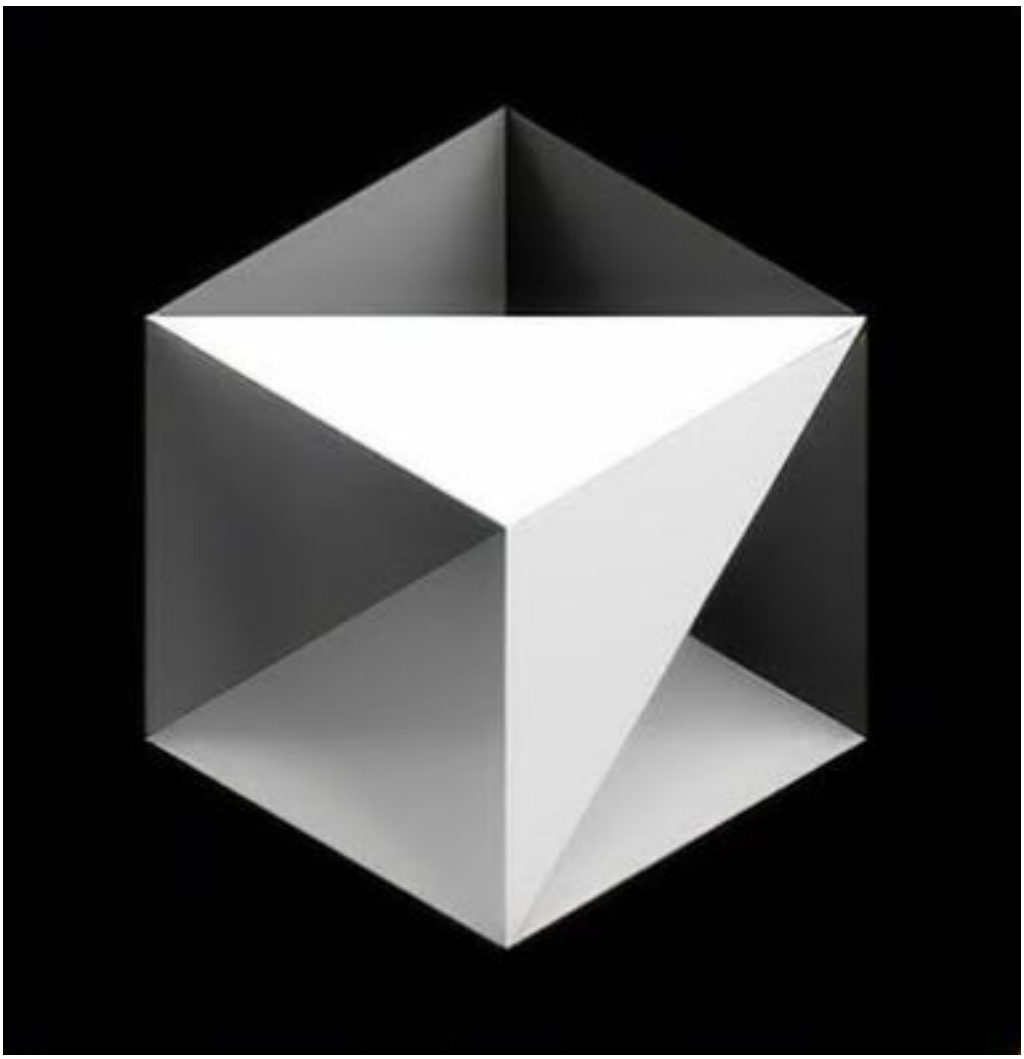

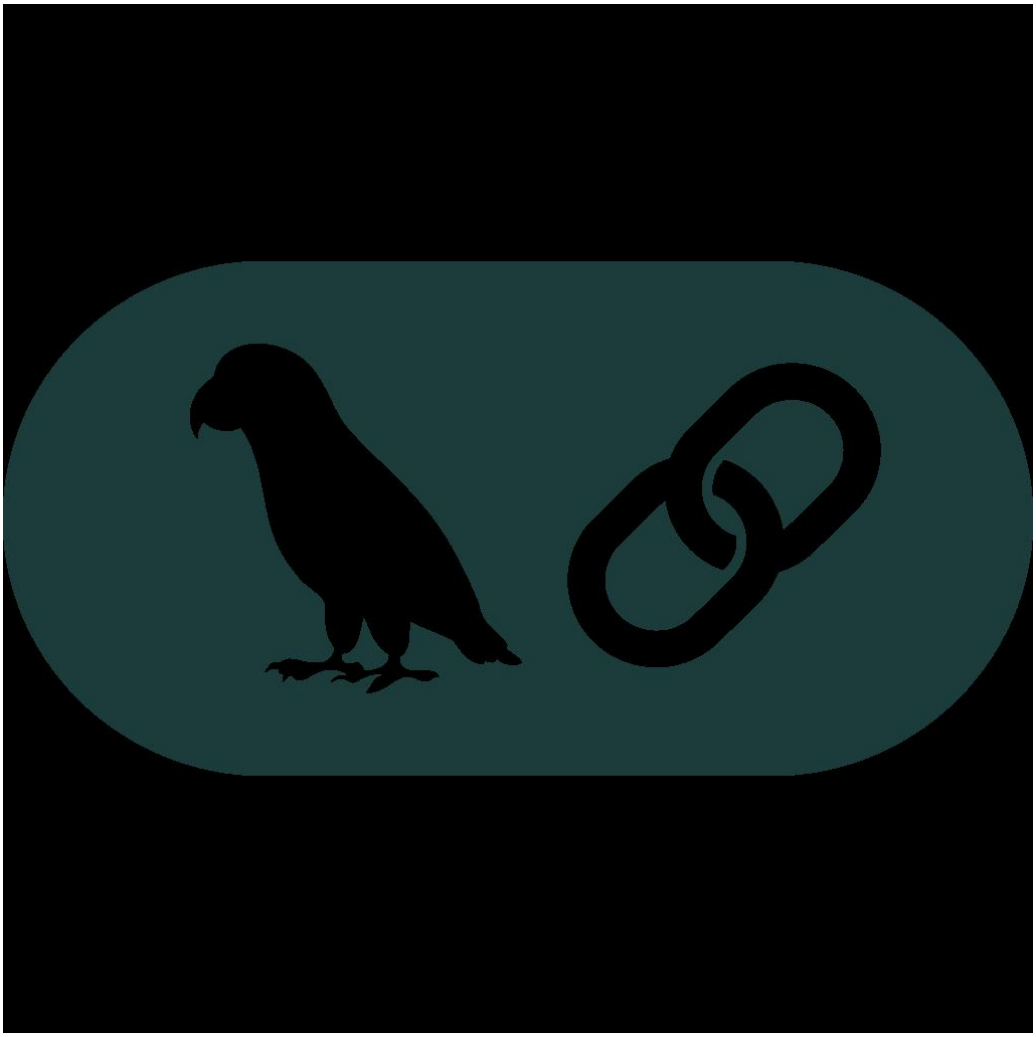

الشات بوت جي بي تي 3

الحوسبة في كل مكان 1999-مجموعة أدوات السياق

الكمبيوتر iPhone Era 1.0 Era 2.0 Era 3.0 Era 4.0 1940 2020 Time

1963 - الواجهة الرسومية Sketchpad

من هذا المنظور الأوسع، يمكن النظر إلى هندسة السياق على أنها عملية تقليل الإنتروبيا. فالآلات، " بشكل فعال أثناء الاتصال. عندما يتفاعل الناس، فإنهم ملء الفجوات على عكس البشر، لا تستطيع " يعتمدون على قدرة المستمع على تقليل إنتروبيا المعلومات بشكل فعال - القدرة على استنتاج السياق المفقود من خلال المعرفة المشتركة، والإشارات العاطفية، والوعي الظرفي (Kapteijns and Hintz، 2021). ونتيجة لذلك، وتفتقر الآلات، على الأقل في الوقت الحاضر، إلى هذه القدرة. " للسياقات الخاصة بهم، وضغط المعلومات الأصلية في نماذج يمكنهم المعالجة المسبقة يتعين علينا " " الأساسي في هندسة السياق: الجهد الذي تحتاج إلى استثماره في تحويل الجهد فهمها. يمثل هذا " السياقات والنوايا ذات الإنتروبيا العالية إلى تمثيلات منخفضة الإنتروبيا يمكن للآلات فهمها. كما هو موضح في الشكل 2، كانت هندسة السياق موجودة دائما لسد الفجوة المعرفية بين الذكاء البشري (القائم على الكربون) والذكاء الآلي (القائم على السيليكون). بينما يتطور الذكاء المعتمد على الكربون نسبيا الشكل 2: مسارات القدرات المعرفية المعتمدة على الكربون والسيليكون مع مرور الوقت. توضح الفجوة الدافع وراء هندسة السياق.

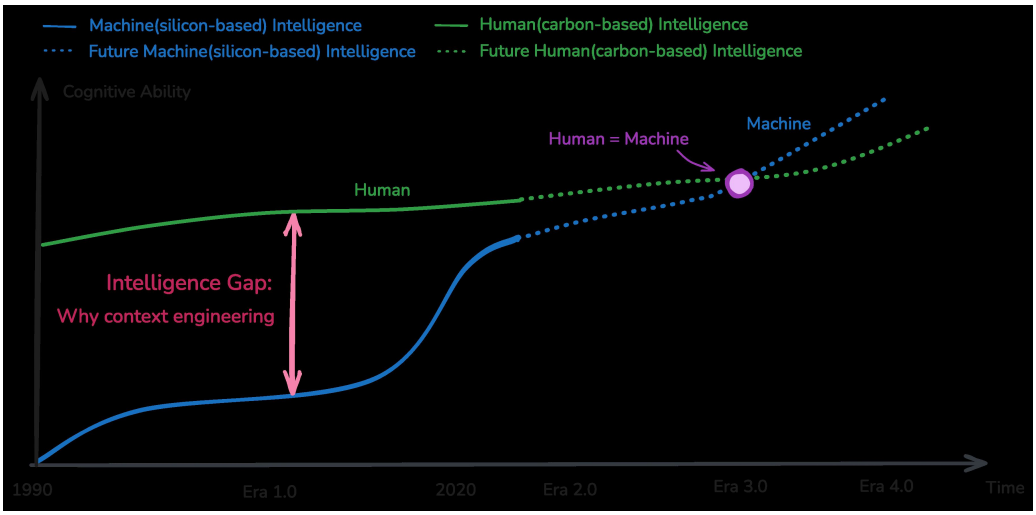

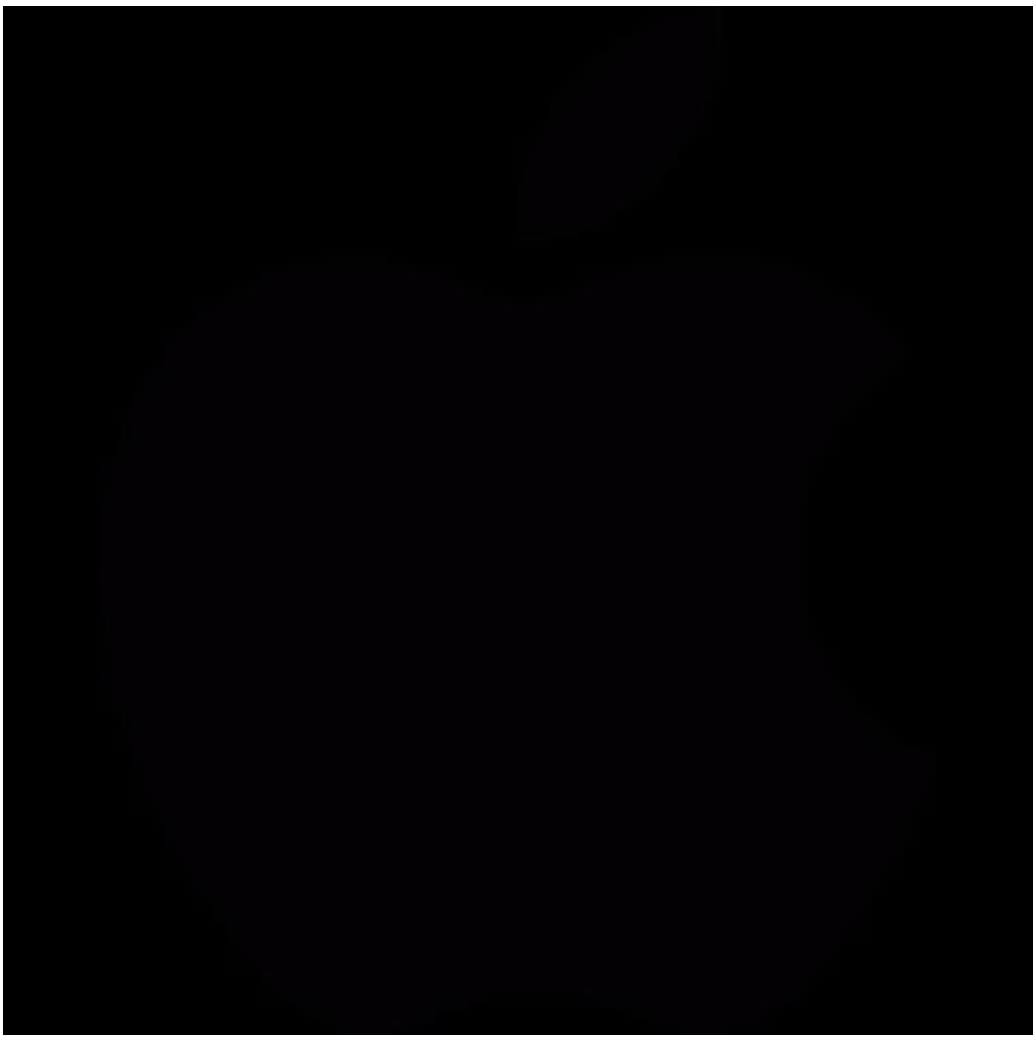

صفحة المصدر 4

2. الإطار النظري SII-GAIR

ببطء، يتكرر الذكاء المعتمد على السيليكون بوتيرة أسرع بكثير. ولذلك، فإن المحرك الرئيسي وراء التحولات النموذجية يكمن في التقدم السريع في الذكاء الآلي. كلما زادت ذكاء الآلات، أصبحت هندسة السياق أكثر طبيعية، وانخفضت تكلفة التفاعل بين الإنسان والآلة. تؤدي كل قفزة نوعية في الذكاء الآلي إلى ثورة جوهرية في الواجهات البينية بين الإنسان والآلة. كما هو موضح في الشكل 3، تؤدي الاختراقات التكنولوجية إلى زيادة القدرة على استيعاب السياق، مما يؤدي إلى ثورات الواجهة ويؤدي في النهاية إلى تحولات نموذجية في هندسة السياق. هذه التحولات ليست تحسينات تدريجية، ولكنها سلسلة من التغييرات النموذجية التي تعيد تشكيل كيفية تواصل البشر والآلات بشكل أساسي.

بناء على هذا النمط المتكرر، يمكننا تصور تطور هندسة السياق كتقدم عبر أربع مراحل متميزة:

هندسة السياق 1.0 - الحوسبة البدائية بمدخلات منظمة ومنخفضة الإنتروبيا (Dey, 2001a)؛ 2.0 — عملاء أذكياء قادرون على تفسير اللغة الطبيعية والتعامل مع الغموض (جينينغز وآخرون، 1998)؛ 3.0 — الذكاء على المستوى البشري، مما يتيح التواصل الدقيق والتعاون السلس (موريس

وآخرون، 2023)؛ و4.0 – الذكاء الخارق، حيث يمكن للآلات بناء السياق بشكل استباقي والكشف عن الاحتياجات التي لم يعبر عنها البشر بوضوح. تستلزم كل مرحلة مقايضات تصميمية مختلفة نوعيا وتسلط الضوء على الأدوار المتغيرة للبشر والآلات. المساهمات الأساسية لهذه الورقة هي كما يلي. أولا، نضع هندسة السياق ضمن منظور تاريخي أوسع، ونتتبع أصولها قبل العوامل الذكية الحديثة. ثانيا، نقدم إطارا نظريا منهجيا ومحددا على نطاق واسع، بما في ذلك جوهر هندسة السياق من منظور تقليل الإنتروبيا ونموذج تطوري من أربع مراحل يعكس التقدم التقني. وأخيرا، نقترح اعتبارات التصميم العامة من خلال مقارنة الممارسات النموذجية، وتوفير التوجيه لتطوير النظام الذكي في المستقبل. في ما تبقى من هذه الورقة، سنقدم أولا تعريفنا لهندسة السياق ونحدد الإطار النظري الذي يرتكز عليه تحليلنا. وسنقوم بعد ذلك بتتبع التطور التاريخي لهذا المجال، مع إيلاء اهتمام خاص للخصائص المميزة للعصرين الأول والثاني. بناء على هذا الأساس، نناقش اعتبارات التصميم التي تتمحور حول ثلاثة أبعاد أساسية: جمع السياق، وإدارة السياق، واستخدام السياق. نقوم بتحليل الممارسات الحالية، وتحديد التحديات الفريدة، واستكشاف الأساليب الناشئة التي قد تشكل التطورات المستقبلية. الشكل 3: العملية التطورية في هندسة السياق

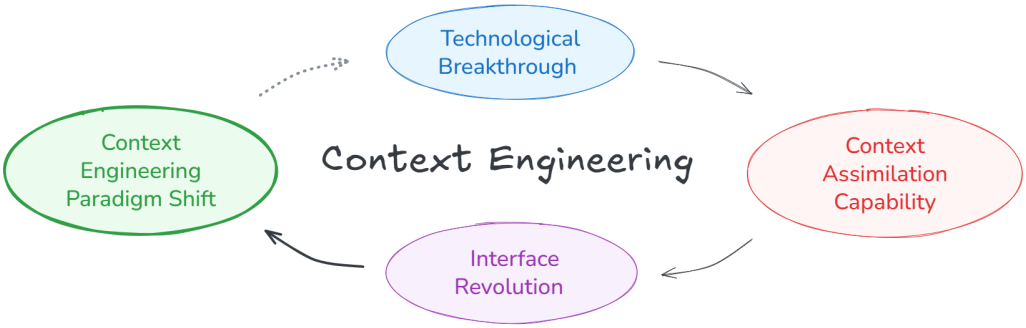

لفهم السياق بشكل أفضل، نبدأ بإضفاء الطابع الرسمي على البنى الأساسية التي تحدد السياق في الأنظمة الحسابية. بناء على تعريف داي التأسيسي للسياق (Dey, 2001b)، فإننا نعبر عن هذه البنيات رياضيا، مما يوفر تمثيلا دقيقا للسياق. واستنادا إلى هذا الصياغة الرسمية، فإننا نحدد هندسة السياق ونفحص كيفية تطورها عبر المراحل المختلفة للذكاء الآلي.2 الإطار النظري

التعريف 1 (الكيان والتوصيف). اجعل E هو الفضاء لجميع الكيانات (المستخدمين والتطبيقات والأشياء والبيئات وما إلى ذلك) وF هو الفضاء لجميع معلومات التوصيف الممكنة. تشير بواسطة P حدد وظيفة التوصيف الظرفي:2.1 التعريف الرسمي، e ∈E بالنسبة لأي كيان .F إلى مجموعة القوة (F)

شار: 1) (E →P (F)

حيث يقوم Char (e) بإرجاع مجموعة المعلومات التي تميز الكيان e. على سبيل المثال، عندما " في Gemini CLI 1، يمكن أن تتضمنالوثائق ذات الصلة بالبحث بالنسبة ليكتب مستخدم " مجموعة الكيانات ذات الصلة المستخدم، وتطبيق Gemini CLI، والبيئة الطرفية، والأدوات الخارجية، ووحدات الذاكرة، وخدمات نموذج الواجهة الخلفية. هنا، يمكن لـ Char (e) أن يصف المستخدم (على سبيل المثال، موجه الإدخال)، والتطبيق

1https://github.com/google-gemini/gemini-cli

صفحة المصدر 5

2.1 التعريف الرسمي SII-GAIR (على سبيل المثال، تعليمات النظام أو التكوين)، والبيئة (على سبيل المثال، دليل العمل الحالي)، والأدوات الخارجية (على سبيل المثال، المكونات الإضافية المتاحة أو أدوات البحث)، ووحدات الذاكرة قصيرة المدى أو طويلة المدى (على سبيل المثال، سجل الجلسة أو المعرفة المخزنة)، والخدمة النموذجية (على سبيل المثال، القدرات المدعومة أو تنسيق الاستجابة). التعريف 2 (التفاعل). يشير التفاعل إلى أي تفاعل يمكن ملاحظته بين المستخدم والتطبيق، بما في ذلك الإجراءات الصريحة (مثل النقرات والأوامر) والسلوكيات الضمنية (مثل أنماط الاهتمام والتعديلات البيئية) التي قد تؤثر أو تتأثر بالنظام الحسابي. في مثال Gemini CLI، التفاعل الصريح هو إدخال أمر المستخدم، في حين أن الجوانب الضمنية يمكن أن تشمل الحالة الطرفية، أو السياق الذي تم استرداده مسبقا، أو استخدام وحدات الذاكرة، أو حالة استدعاء الأداة. التعريف 3 (السياق). بالنسبة لتفاعل مستخدم مع تطبيق معين، يتم تعريف السياق على النحو التالي:

C = [e∈Erel شار (e) (2)

حيث Erel ⊆E هي مجموعة الكيانات التي تعتبر ذات صلة بالتفاعل. وهذا يجسد السياق باعتباره أي معلومات يمكن استخدامها لوصف حالة الكيانات التي تعتبر ذات صلة بالتفاعل بين المستخدم" " (Dey, 2001b). في نفس المثال، يمكن لـ Erel تضمين المستخدم، وتطبيق Geminiوالتطبيق .والبيئة الطرفية، والأدوات الخارجية، ووحدات الذاكرة، وخدمات نموذج الواجهة الخلفية ،CLI السياق العام C هو تجميع هذه التوصيفات. التعريف 4 (هندسة السياق). هندسة السياق هي عملية منهجية لتصميم وتحسين جمع السياق وتخزينه وإدارته واستخدامه لتعزيز فهم الآلة وأداء مهامها. ومن الناحية الرسمية يمكن تعريفها على النحو التالي:

CE : (C, T) →fcontext (3)

حيث تشير C إلى المعلومات السياقية الأولية كما هو محدد في المعادلة (2)، وتمثل T المهمة المستهدفة أو مجال التطبيق، وfcontext هي وظيفة معالجة السياق الناتجة التي تعمل على تحويل تمثيلات السياق وتحسينها لتحسين أداء المهمة. يشمل fcontext تكوينا مرنا لعمليات معالجة السياق:

$$f_{context}(C) = F(\phi_1, \phi_2, \ldots, \phi_n)(C) \quad (4)$$

يمكن أن يتضمن التركيب F معالجة متوازية، أو تحسينا تكراريا، أو تفرعا مشروطا، أو أي مجموعة من العمليات المصممة خصيصا لمتطلبات التطبيق المحددة. عمليا، قد تتضمن مجموعة العمليات في هندسة السياق 2.0 ما يلي: (1) جمع المعلومات السياقية ذات الصلة من خلال أجهزة {φi} الاستشعار أو القنوات الأخرى، (2) تخزينها وإدارتها بكفاءة، (3) تمثيلها بتنسيق متسق وقابل للتشغيل البيني، (4) التعامل مع المدخلات متعددة الوسائط من النص أو الصوت أو الرؤية، (5) دمج)، (6) اختيار العناصر السياقية الأكثر صلة، (7)"الخبز الذاتي"السياق السابق وإعادة استخدامه (مشاركة السياق عبر الوكلاء أو الأنظمة، و(8) تكييف السياق ديناميكيا بناء على التعليقات أو الأنماط المستفادة. حيث تمثل F وظيفة تكوين تجمع بين عمليات هندسة السياق المختلفة φi. نطاق هندسة السياق يتجنب هذا التعريف عمدا قصر هندسة السياق على أي تقنية أو عصر محدد. سواء كان الكيان المتلقي جهاز كمبيوتر بدائيا من التسعينيات مزودا بواجهة رسومية أو وكيلا لعام 2025، فإن التحدي الأساسي يظل كما هو: كيفية فهم السياقات والنوايا بدقة. تتطور التقنيات والأشكال المحددة المستخدمة في هندسة السياق مع التكنولوجيا، ولكن التحدي الأساسي المتمثل في سد الفجوة بين نوايا الإنسان وفهم الآلة يظل ثابتا. لماذا هذا التعريف مهم؟ يخدم هذا التعريف الأوسع عدة أغراض مهمة. أولا، يربط بين الممارسات الهندسية السريعة الحالية والتاريخ الغني لتصميم واجهة الإنسان والحاسوب، مما يسمح لنا بالتعلم من عقود من المعرفة المتراكمة. ثانيا، يوفر إطارا نظريا يمكنه تفسير سبب نجاح بعض تصميمات السياق عبر تقنيات وعصور مختلفة. ثالثا، يوفر أساسا للتنبؤ بكيفية تطور هندسة السياق مع استمرار تقدم قدرات فهم الآلة. ومن خلال فهم هندسة السياق باعتبارها جانبا أساسيا للتواصل بين الإنسان والآلة بدلا من كونها ممارسة تقنية ضيقة، يمكننا أن نقدر تطورها التاريخي ومسارها المستقبلي بشكل أفضل. ويكشف هذا المنظور عن هندسة السياق ليس باعتبارها اختراعا حديثا، بل باعتبارها نظاما متطورا سيستمر في التكيف مع تحول طبيعة التفاعل بين الإنسان والآلة نفسها.

صفحة المصدر 6

2.2 توصيف المرحلة SII-GAIR

ومن أجل فهم هندسة السياق بشكل أفضل، يجب علينا توسيع وجهة نظرنا إلى ما هو أبعد من اللحظة الحالية والاعتراف بها باعتبارها جانبا أساسيا من التواصل بين الإنسان والآلة الذي ظل يتطور بشكل مستمر لعقود من الزمن؛ ويمكن وصف هذا التطور المستمر من خلال أربع مراحل، تتماشى كل منها مع التقدم الكبير في الذكاء الآلي. على وجه التحديد، يمكن اعتبار ذكاء الآلة يتقدم من خلال المراحل التالية: (i) الحساب البدائي، (ii) الذكاء المتمركز حول العميل، (iii) الذكاء على المستوى

البشري، و(iv) الذكاء الخارق. وكان بإمكانهم معالجة المدخلات المنظمة والتعرف على الإشارات البيئية البسيطة، لكنهم افتقروا إلى فهم أعمق للمعنى أو القصد. تعتمد التفاعلات بين الإنسان والآلة على تنسيقات صارمة ومحددة مسبقا، مثل الاختيار من القوائم أو استخدام بيانات الاستشعار البسيطة كمدخلات. على الرغم من أن هذا العصر تجاوز أوامر المستوى الثنائي، إلا أنه لا يزال يتعين إعداد جميع السياقات بشكل واضح وترجمتها إلى تنسيقات يمكن للآلة معالجتها مباشرة (Shneiderman, 1987). العصر 2.0: الذكاء المرتكز على العميل (2020 إلى الوقت الحاضر) يمثل ظهور LLM، الذي تجسد في إصدار GPT-3 في عام 2020 (Floridi and Chiriati, 2020; Brown et al., 2020)، نقطة تحول لهندسة السياق والذكاء المرتكز على العميل. تظهر الآلات في هذه المرحلة ذكاء معتدلا، يتميز بالقدرة على فهم مدخلات اللغة الطبيعية واستنتاج بعض النوايا الضمنية. أصبح التعاون بين الإنسان والآلة قابلا للتطبيق بشكل متزايد، حيث أصبح المستخدمون قادرين على التعبير عن احتياجاتهم عن طريق المحادثة ويمكن للأنظمة تفسير الكثير من المعنى الأساسي. لم يعد السياق يقتصر على إشارات محددة بوضوح؛ يمكن أن يشمل الغموض والمعلومات غير الكاملة. يفكر الوكلاء بنشاط في الفجوات السياقية، باستخدام فهم اللغة المتقدم والتعلم في السياق لتوفير تفاعلات أكثر تكيفا واستجابة (بوماساني وآخرون، 2021). العصر 3.0: الذكاء على المستوى البشري (المستقبل) مع الاختراقات المتوقعة، من المتوقع أن تقترب الأنظمة الذكية من التفكير والفهم على المستوى البشري (Goertzel and Pennachin, 2021). في هذه المرحلة، تتجاوز هندسة السياق النمط الحالي، مما يمكن الوكلاء من استشعار السياقات واستيعاب المعلومات ذات الإنتروبيا العالية مثل البشر. يتوسع نطاق السياق القابل للتفسير بشكل كبير، مثل الإشارات الاجتماعية، والحالات العاطفية، والديناميكيات البيئية الأكثر ثراء. ومثل هذه التطورات تمكن من التعاون الطبيعي بين الإنسان والآلة، حيث يعمل الذكاء الاصطناعي كأقران ذوي معرفة وفعالية. العصر 4.0: الذكاء الخارق ، وفهم"نظرة عين الله(التأملي) مع تجاوز الأنظمة الذكية للقدرات البشرية، فإنها تبدأ في امتلاك " نوايا الإنسان بشكل أعمق من البشر أنفسهم. في هذه المرحلة، تنقلب العلاقة التقليدية بين الذات والموضوع: فبدلا من أن تتكيف الآلات بشكل سلبي مع السياقات التي يحددها الإنسان، فإنها تعمل بنشاط على بناء سياقات جديدة للبشر، وتكشف عن الاحتياجات الخفية، وتوجه التفكير البشري. بدأت تظهر بالفعل علامات هذا التحول، على سبيل المثال، في لعبة Go، يتعلم اللاعبون المحترفون استراتيجيات جديدة وخارقة من الذكاء الاصطناعي. وبهذه الطريقة، تصبح الآلات مصادر والإلهام، مما يعيد بشكل أساسي تعريف طبيعة التعاون بين الإنسان والآلة (سيلفر وآخرون، 2016). للبصيرة

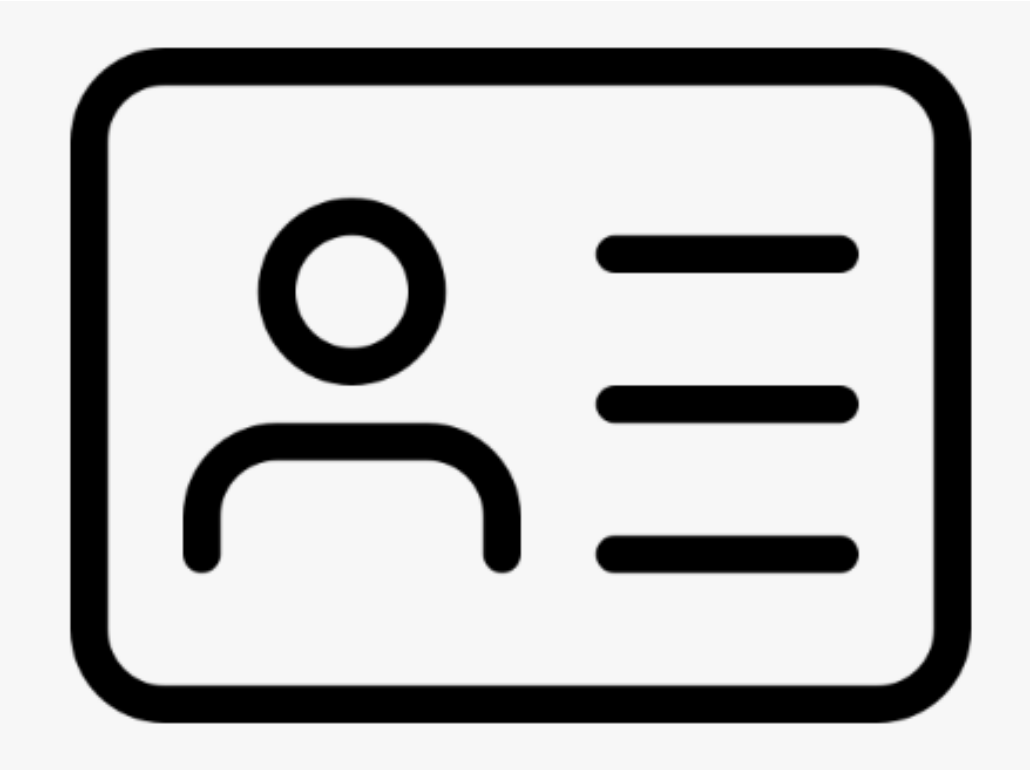

3 التطور التاريخي

هندسة السياق الجانب 1.0 هندسة السياق 2.0

الفترة الزمنية 1990–2020 2020–الحاضر الخلفية التقنية الحوسبة في كل مكان، الأنظمة المدركة للسياق، HCI نماذج اللغات الكبيرة، الوكلاء، الهندسة الفورية مجموعة أدوات سياق الأنظمة النموذجية، Letta، AutoGPT، LangChain، ChatGPT contextPhone، Cooltown طرائق السياق الموقع، الهوية، النشاط، الوقت، البيئة، حالة الجهاز

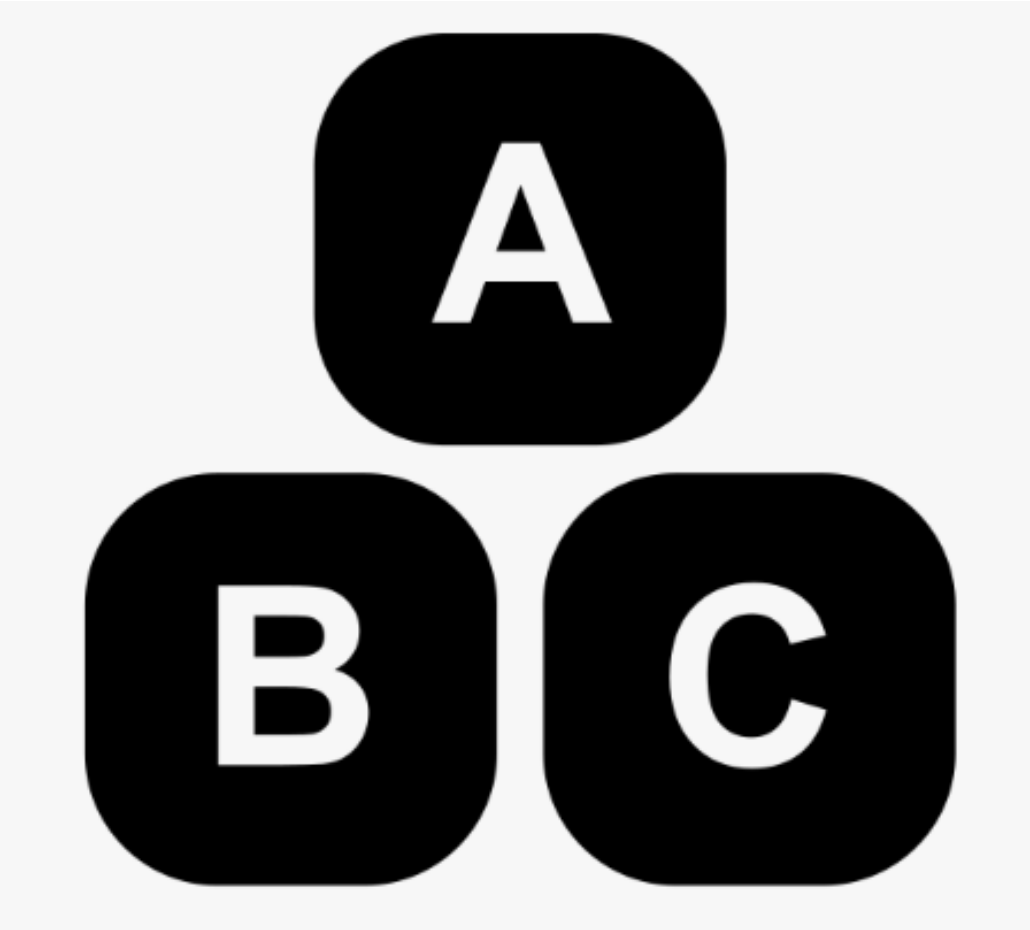

تسلسلات الرمز المميز، المستندات المستردة، واجهات برمجة تطبيقات الأدوات، سجل المستخدم الآليات الأساسية دمج المستشعر، مشغلات القاعدة المطالبة، CoT، RAG، عوامل الذاكرة تسامح السياق منخفض نسبيا مرتفع نسبيا التشابه البشري منخفض نسبيا مرتفع نسبيا

لفهم كيفية تطور هندسة السياق بشكل أفضل، قمنا بمقارنة خصائصها الأساسية عبر عصرين رئيسيين. تتناول الأقسام التالية أسس هندسة السياق في تطورها المبكر (العصر 1.0) والتطورات المهمة التي تحدد المشهد الحالي (العصر 2.0). الجدول 1: مقارنة بين هندسة السياق 1.0 و2.0 عبر الأبعاد التمثيلية

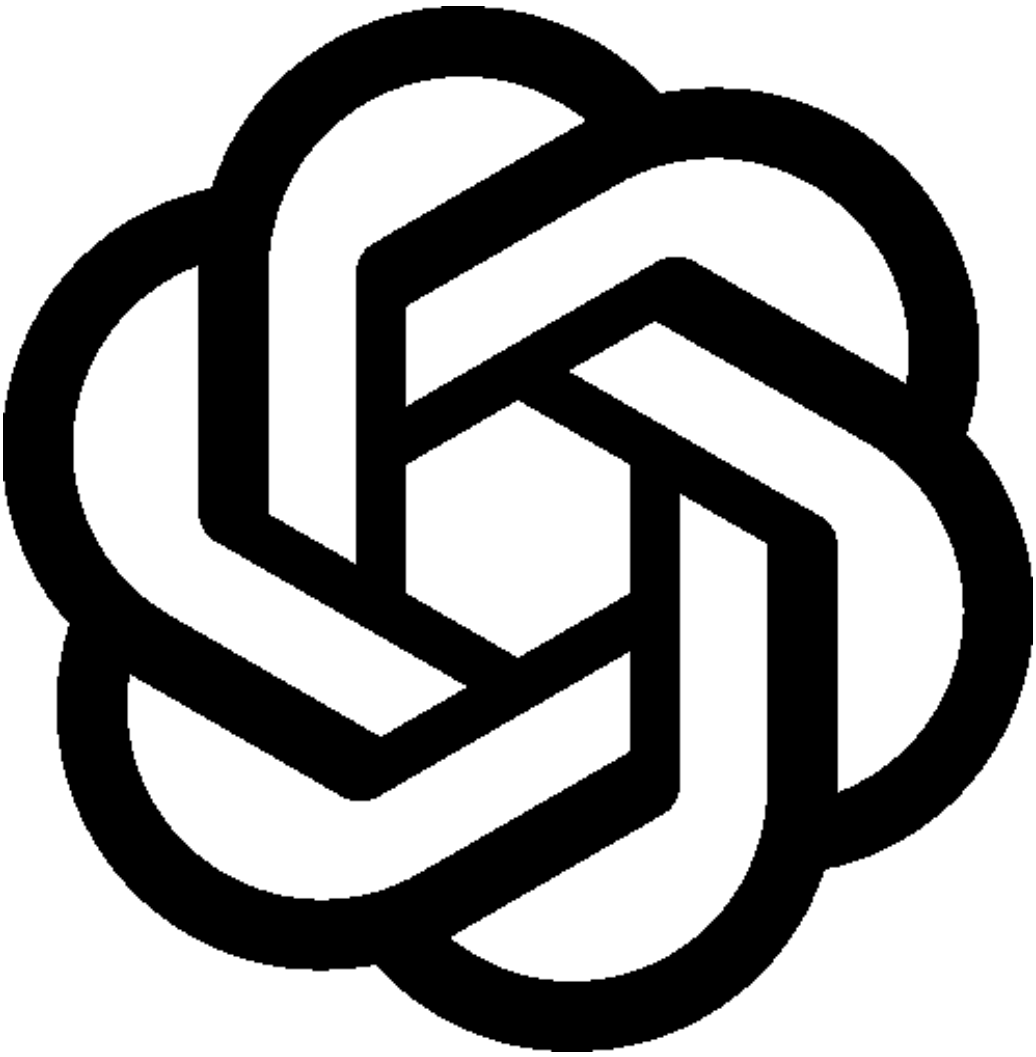

صفحة المصدر 7

3.1 منذ أكثر من 20 عاما: العصر SII-GAIR 1.0

نحن نعرف هندسة السياق بأنها ممارسة تمكين الفهم والتواصل الفعال بين البشر والآلات. في عصر هندسة السياق 1.0، يكون البشر مسؤولين عن توفير السياق، في حين أن أجهزة الكمبيوتر البدائية

هي متلقي المعلومات. يمتد هذا العصر في المقام الأول من التسعينيات إلى عام 2020. في هندسة السياق 1.0، يكافح البشر للتكيف مع الآلات: عمل المصممون بمثابة "مترجمي النوايا" بتحويل النوايا البشرية المعقدة إلى تنسيقات منظمة يمكن قراءتها آليا. وهذا يتناقض مع العصر الحديث للذكاء الاصطناعي الذي يتمتع بقدرات الفهم الدلالي، حيث يمكن للآلات تفسير المعلومات غير المنظمة وعالية الإنتروبيا بشكل مستقل. 3.1 منذ أكثر من 20 عاما: عصر 1.0 3.1.1 المشهد التكنولوجي لفهم هندسة السياق 1.0، يجب علينا أولا أن نأخذ في الاعتبار المشهد التكنولوجي في الثمانينيات والتسعينيات. تميزت هذه الفترة بالانتقال من واجهات سطر الأوامر (CLI) إلى واجهات المستخدم الرسومية (GUI)، مما جعل أجهزة الكمبيوتر في متناول عامة الناس. ومع ذلك، فإن هذا التحول لم يزيل العبء المعرفي على المستخدمين. وبدلا من ذلك، أعادت تعريف كيفية تفاعل البشر مع الآلات، مما يتطلب تكيفات دقيقة مع القيود التي فرضتها التقنيات في ذلك الوقت. في عام 1991، قدم مارك وايزر مفهوم الحوسبة في كل مكان (وايزر، 1991)، متصورا التكامل السلس للحوسبة في البيئات اليومية. اقترحت هذه الرؤية أن الأجهزة يمكنها تقديم الخدمات دون الحاجة إلى إدخال نشط من المستخدم. بناء على هذه الفكرة، ظهرت الحوسبة المدركة للسياق كإطار لاستكشاف ما إذا كانت الأنظمة يمكنها استشعار حالات المستخدم والبيئات والمهام لتكييف سلوكها ديناميكيا (Schilit and Theimer, 1994; Abowd et al., 1999a). أدى هذا إلى طرح أسئلة أساسية: ما هو "السياق" بالضبط؟ كيف يمكن تعريفها ومعالجتها وجعلها قابلة للاستخدام بواسطة الآلات؟ على الرغم من هذه التطورات المفاهيمية، كانت القيود التكنولوجية في ذلك الوقت كبيرة. يمكن للآلات تنفيذ منطق البرنامج المحدد مسبقا فقط، كما أنها تفتقر إلى القدرة على فهم دلالات اللغة الطبيعية، أو التفكير في المشكلات، أو التعامل مع الأخطاء بشكل فعال. أدى هذا إلى خلق فجوة كبيرة بين التفكير البشري وقدرات المعالجة الآلية. ولسد هذه الفجوة، قدمت هندسة السياق استراتيجيات لجعل النوايا البشرية قابلة للتنفيذ بواسطة الآلات. كان على المصممين تحليل الأهداف المعقدة إلى مكونات بسيطة منظمة يمكن للآلات معالجتها. يجب تصميم مسارات تفاعل واضحة لضمان قدرة الآلات على اتباع المنطق المحدد مسبقا. بالإضافة إلى ذلك، تم تنفيذ آليات التغذية الراجعة للسماح بالتعديلات بناء على مدخلات المستخدم أو التغييرات البيئية. وكانت هذه الاستراتيجيات ضرورية للتغلب على القيود المفروضة على الآلات وتمكينها من التصرف بناء على النية البشرية بفعالية. وشدد هذا التعريف على الطبيعة المتعددة الأبعاد للسياقات. لقد وضع عمل داي الأساس لالتقاط السياق واستخدامه بشكل منهجي لتحسين قدرة النظام على التكيف وتجربة المستخدم. كان العمل النظري في هذا العصر واسعا وعميقا (Baldauf et al., 2007b)، مع التركيز على الفهم الشامل للسياق. وهذا يتناقض مع التركيز الأضيق اليوم، والذي غالبا ما يعزل جوانب معينة من السياق، مثل سجل الدردشة. ويمثل تضييق هذا التركيز خطوة إلى الوراء. يمكن أن تساعد

إعادة النظر في النظريات الأساسية لهندسة السياق 1.0 في معالجة هذا الانحدار وإلهام أساليب أكثر شمولا للأنظمة المدركة للسياق. 3.1.2 الأسس النظرية شهدت أوائل العقد الأول من القرن الحادي والعشرين ظهور أطر نظرية قوية لهندسة السياق. من بينها، برز تعريف Anind K. Dey لعام 2001 السياق هو أي معلومات يمكن استخدامها لوصفللسياق باعتباره حجر الزاوية (Dey, 2001a): " حالة كيان ما. الكيان هو شخص أو مكان أو كائن يعتبر ذا صلة بالتفاعل بين المستخدم والتطبيق، . 3.1.3 الممارسات الأساسية في عصر هندسة السياق 1.0،"بما في ذلك المستخدم والتطبيقات نفسها كان الابتكار الرئيسي هو التحول من أجهزة الإدخال التقليدية، مثل لوحات المفاتيح والفئران، إلى نموذج موزع يتمحور حول أجهزة الاستشعار (Schilit and Theimer, 1994; Abowd and Mynatt, 2000). يعكس هذا التحول الحاجة الناشئة إلى التقاط الإشارات السياقية الأكثر ثراء بشكل مستمر من كل من المستخدمين والبيئات المحيطة بهم. بناء على هذه الرؤية، قدم أنيند داي إطارا عاما للأنظمة المدركة للسياق والتي وفرت الأساس المفاهيمي والمعماري لهذا الجيل (داي، 2001أ). تم إنشاء إطار العمل من خلال مجموعة أدوات السياق، التي حددت إطارا معياريا وقابلا لإعادة الاستخدام لدعم اكتساب السياق وتفسيره وتسليمه (Salber et al., 1999). تم تنظيمه حول خمسة تجريدات أساسية: أدوات السياق، والمترجمون الفوريون، والمجمعون، والخدمات، والمكتشفون. أدوات الاستشعار المغلفة والواجهات الموحدة المكشوفة؛ استمد المترجمون الفوريون معنى عالي المستوى من البيانات السياقية الأولية؛ قام المجمعون بدمج مصادر سياق متعددة؛ عرضت الخدمات الوصول على مستوى التطبيق إلى الوظائف السياقية؛ وقام المكتشفون بتمكين التسجيل الديناميكي واكتشاف مكونات السياق (Salber et al., 1999). أنشأ هذا الفصل المعماري بين الاهتمامات أساسا عمليا للأنظمة الواعية للسياق القابلة للتطوير والتكيف، مما يمثل خطوة حاسمة في إضفاء الطابع الرسمي على ممارسات هندسة السياق المبكرة.

صفحة المصدر 8

3.2 بعد 20 عاما: العصر SII-GAIR 2.0 باختصار، وضعت هندسة السياق 1.0 التفكير التأسيسي والنماذج المعمارية لبناء أنظمة سريعة الاستجابة. لقد جمع أفكارا من الحوسبة في كل مكان وتفاعل التفاعل بين الإنسان، وأنشأ تجريدات أساسية من خلال إضفاء الطابع الرسمي على Anind Dey ومكن من التنفيذ العملي من خلال تصميمات معيارية تعتمد على أجهزة ،(Salber et al., 1999) الاستشعار. على الرغم من محدودية التعبير وقابلية التوسع، فقد وفرت هذه المرحلة الأساس الأساسي للتصميمات الأكثر تقدما التي أعقبت عصر هندسة السياق 2.0.

يمثل التطور من هندسة السياق 1.0 إلى 2.0 قفزة كبيرة في الذكاء الآلي، والانتقال من الحوسبة البدائية إلى الوكلاء الأذكياء (Ye et al., 2025a). بالمقارنة مع العصر 1.0، الذي سيطر عليه المنطق القائم على القواعد وإدخال أجهزة الاستشعار المنظمة، يقدم الوكلاء تطورات كبيرة عبر مسار السياق. تمتد هذه التحسينات من كيفية اكتساب السياق إلى كيفية تحمل الإشارات الأولية وتفسيرها واستخدامها في النهاية للسلوك الذكي. على وجه الخصوص، التحولات التالية تميز التطور:

3.2 بعد 20 عاما: العصر 2.0 اكتساب السياق: أجهزة الاستشعار المتقدمة في العصر 2.0، تظل المستشعرات أساسية لاكتساب السياق. أدى التقدم في تكنولوجيا الاستشعار، مثل الهواتف الذكية والأجهزة القابلة للارتداء والأجهزة المحيطة، إلى توسيع نطاق وتغطية السياقات المتاحة بشكل كبير. لا تؤكد هندسة السياق 2.0 على التنوع الأوسع لأجهزة الاستشعار فحسب، بل تؤكد أيضا على القدرة على استخلاص إشارات سياقية متنوعة من كل مستشعر على حدة.

نص هاتف ذكي، صورة، صوت، موقع، رسائل تعمل باللمس، صور، صوت كمبيوتر (كمبيوتر محمول/كمبيوتر شخصي) نص، صورة، ضغطة مفتاح، حركة المؤشر بالماوس، كتابة حوسبة شخصية ساعة ذكية معدل ضربات القلب، حركة، نبض صوتي، خطوات، جهاز الفئة/المجمع، الطرائق

المجمعة مثال إدخال نظارات ذكية/سماعة رأس AR فيديو، نظرة، صوت، سياق المشهد تتبع العين، الفيديو المحيط وحدة تحكم VR/AR الحركة، إيماءة ردود الفعل اللمسية، الضغط على الزر تقنية غامرة مكبر صوت ذكي الصوت، محادثات الأوامر الصوتية، نغمة الصوت، واجهة الدماغ والكمبيوتر، الإشارات العصبية، EEG العاطفي، الإثارة، الحمل المعرفي، أجهزة استشعار الجلد/الأجهزة القابلة للارتداء، درجة الحرارة، استجابة كلفانية، الإجهاد، العاطفة، ضغط اللمس، الاستشعار الفسيولوجي، تعقب العين، النظرة، الرمش، تمدد حدقة العين، أنماط التثبيت، تحويل الانتباه، نظام السيارة، الموقع، النظرة، سلوك القيادة، أسلوب القيادة، اتجاه العين، أجهزة إنترنت الأشياء المنزلية، البيئة، الصوت، درجة حرارة الحركة، استخدام الأجهزة الأنظمة البيئية، تتبع السلوك عبر الإنترنت، النص، نية البحث التمرير، وأنماط الاهتمام ،Clickstream

التسامح مع السياق الخام: من المدخلات المنظمة إلى الإشارات البشرية الأصلية قبل الوصول إلى مستوى الذكاء البشري، يخضع ذكاء النظام بشكل أساسي لدرجة التشابه مع الإنسان، والتي يتم قياسها بشكل أفضل من خلال تحمله للسياق الخام، أو بعبارة أخرى، القدرة على استهلاك ومعالجة مدخلات المعلومات ذات الإنتروبيا العالية. في عصر الأنظمة المدركة للسياق 1.0، كان الإدخال يقتصر على إشارات بسيطة ومنظمة مثل إحداثيات نظام تحديد المواقع العالمي (GPS)، أو الوقت من اليوم، أو حالات المستخدم المحددة مسبقا (Baldauf et al., 2007b; Dey, 2001a). كانت هذه الميزات سهلة المعالجة، ولكنها تطلبت من المطورين أن يحددوا مسبقا ما يمكن اعتباره سياقا ذا معنى. في المقابل، يمكن للأنظمة الحديثة في عصر 2.0 تفسير السياق من الإشارات التي تشبه التعبير البشري الطبيعي، مثل النص الحر أو الصور أو الفيديو (Radford et al., 2021; Alayrac et al., 2022a). لا يقتصر هذا التحول على إضافة أنواع مدخلات جديدة فحسب؛ فهو يعكس تحسنا أعمق في قدرة النظام على فهم البيانات الفوضوية والغامضة وغير المكتملة. بفضل التقدم في النماذج الأساسية والإدراك متعدد الوسائط، يمكن لهذه الأنظمة الآن التعامل مع المدخلات التي كانت تعتبر في السابق خاما جدا أو غير منظمة. ونتيجة لذلك، يمكن استيعاب السياق مباشرة في شكله الأصلي، دون الحاجة إلى معالجة مسبقة ثقيلة. يمثل هذا خطوة أساسية نحو المرونة على المستوى البشري في تفسير السياق. الجدول 2: جامعي السياق التمثيلي متعدد الوسائط حسب الفئة فهم السياق واستخدامه: من الاستشعار السلبي إلى الفهم النشط والتعاون تعمل الأنظمة المدركة للسياق في عصر 1.0 عادة بموجب قواعد التصرف الشرطي البسيطة (Schilit and Theimer, 1994; Abowd and Mynatt, 2000). وبعبارة أخرى، فقد استشعروا إشارات محددة مسبقا وأثاروا استجابات ثابتة. على سبيل المثال، " تستجيب هذه الأنظمة وفقاإذا كان الموقع هو المكتب، فقم بإسكات الهاتف." للمكان الذي تتواجد فيه، وليس لما تفعله. في المقابل، تهدف أنظمة 2.0 إلى تفسير ما يفعله

المستخدم بشكل فعال والتعاون لتحقيق الأهداف المشتركة. على سبيل المثال، عندما تكتب ورقة بحثية، يمكن للنظام تحليل فقراتك السابقة ونواياك الكتابية الحالية لاقتراح القسم التالي المناسب. فهو لا يستشعر بيئتك فقط؛ فهو يتكامل مع سير العمل الخاص بك. وهذا ما نسميه تعاونية السياق؛ نحن نتطور من الأنظمة الواعية بالسياق إلى الأنظمة التعاونية.

صفحة المصدر 9

4. جمع السياق وتخزينه SII-GAIR

جمع السياق والتخزين

كيف يمكن جمع السياق وتخزينه بأمان؟

سكليتي [41] ؛ المستوى-35] elDB]

قم بوضع علامة على السياق باستخدام الطابع الزمني 60] MemOS] ؛ 61] Manus] وضع علامات على السياق حسب الدور أو الوظيفة 112] LLM4Tag] الضغط باستخدام أزواج ضمان الجودة والإدراك العميق [120]

استخدام تمثيل مشترك عبر الأنظمة [105 Sharedrop]

كيفية معالجة السياق النصي بأمان؟

الضغط باستخدام الملاحظات الهرمية [121 SII CLI]

تشفير المدخلات متعددة الوسائط في مساحة متجهة قابلة للمقارنة

[كلود [8 ; [79] ChatGPT

الجمع بين الطرائق المشفرة بشكل مستقل للاهتمام بالذات

كيف يمكن دمج السياقات المتعددة الوسائط بشكل فعال؟

[كلود [8 ; [79] ChatGPT

استخدام طريقة واحدة للحضور إلى طريقة أخرى عبر الانتباه المتبادل [127 Qwen2-VL]

إدارة السياق

اعتبارات التصميم

بنية الطبقات للذاكرة [91 UI-TARS]

كيف يمكن إدارة السياقات؟

الوكيل الفرعي: عزل السياق الوظيفي كلود [9]

قم بتخزين السياق الأولي، ثم قم بإضافة ملخصات باللغة الطبيعية

كود كلود [10] ; الجوزاء كلي [34]

قم بتخزين السياق الأولي، ثم استخرج الحقائق الأساسية باستخدام المخطط الثابت ChatSchema [126] قم بتخزين المعلومات مباشرة بتنسيق منظم للخبز الذاتي [40 HMT]

كيف يمكن للسياق أن يؤدي عملية الخبز الذاتي؟

ضغط السياق تدريجيا إلى متجهات المعنى [110 H-MEM]

كيف نختار السياق المناسب للفهم الفعال؟

ليتا [119] ; [137 MEM1]

تضمين السياق السابق في المطالبات

أوتو[116 GPT] ; تشات ديف [90]

كيف يمكن للوكلاء المختلفين مشاركة السياق بفعالية؟

تبادل الرسائل المنظمة بين الوكلاء

ليتا [119] ; ميمو [39]

استخدام السياق

ليتا [119] ; أ- [20 MEM]

استخدام الذاكرة المشتركة للتواصل غير المباشر

كيف يمكن مشاركة السياق عبر أنظمة مختلفة؟ استخدم المحولات لتحويل السياق [57 Langroid]

كيف يمكن للذكاء الاصطناعي استنتاج احتياجات المستخدم وتفضيلاته بشكل استباقي؟

[كلود [8 ; [79] ChatGPT

الشكل 4: اعتبارات التصميم الخاصة بهندسة السياق عبر العصور المختلفة، لاحظ أن الأمثلة المذكورة لا تغطي سوى مجموعة فرعية

نظرا لأن بيئات الحوسبة أصبحت أكثر تعقيدا، هناك حاجة متزايدة لقدرات جمع السياق المحسنة. واستجابة لذلك، فإن التقدم في تقنيات الاستشعار والذكاء الاصطناعي يجعل من الممكن الآن جمع السياق من مصادر أكثر ثراء (أو أجهزة استشعار). لقد تنوعت مساحة التخزين أيضا عبر الأجهزة المحلية، وخوادم الشبكات، والمنصات السحابية، وما إلى ذلك، ولكل منها مقايضات مختلفة من حيث زمن الوصول والسعة وقابلية التوسع والأمان. هناك مبدآن أساسيان للتصميم يوجهان هذه العملية. ينص مبدأ الحد الأدنى من الاكتفاء على أن الأنظمة يجب أن تجمع وتخزن فقط المعلومات الضرورية لدعم المهمة: قيمة السياق تكمن في الكفاية، وليس الحجم. يؤكد مبدأ الاستمرارية الدلالية على أن الغرض من السياق هو الحفاظ على استمرارية المعنى، وليس مجرد استمرارية البيانات. تشكل هذه المبادئ معا كيفية جمع السياق والحفاظ عليه في أنظمة ذكية وموثوقة. جمع السياق وتخزينه

في المراحل المبكرة، تم جمع السياق بشكل أساسي على جهاز واحد، مثل كمبيوتر مكتبي أو هاتف ذكي مبكر، باستخدام أجهزة استشعار محدودة (نظام تحديد المواقع العالمي (GPS)، والساعة، وأحداث لوحة المفاتيح/الماوس) أو سجلات التطبيقات التي تسجل أنماط الاستخدام وتفاعلات المستخدم (Schilit and Theimer, 1994; Dey, 2001a; Abowd et al., 1999b). كانت ممارسات التخزين في هذه الفترة محلية إلى حد كبير. يتم تسجيل بيانات السياق عادة كملفات سجل أو مستندات منظمة داخل نظام الملفات المحلي أو يتم تخزينها في قواعد بيانات محلية بسيطة. غالبا ما يتم الاحتفاظ بالحالات المؤقتة، مثل إدخالات المستخدم الأخيرة أو أنشطة النافذة، في ذاكرة التخزين المؤقت للذاكرة أو المجلدات المؤقتة ويتم التخلص منها عند إيقاف تشغيل النظام. على الرغم من أن بعض الأنظمة حاولت تحميل السياق إلى خوادم مركزية، إلا أن هذه الجهود كانت مقيدة بزمن الوصول العالي والاتصال غير المستقر بالشبكة (ساتيانارايانان، 2001). بشكل عام، أعطت استراتيجيات التخزين في هذا العصر الأولوية 4.1 الاستراتيجيات النموذجية في العصر 1.0 و2.0

صفحة المصدر 10

التوفر المستقل على جهاز واحد بدلا من المزامنة عبر الأجهزة أو الحماية الآمنة للبيانات. ومع التقدم التكنولوجي، أصبحت مجموعة السياق موزعة عبر نقاط نهاية متعددة، بما في ذلك الهواتف الذكية والأجهزة القابلة للارتداء وأجهزة الاستشعار المنزلية والخدمات السحابية وواجهات برمجة التطبيقات التابعة لجهات خارجية (Lane et al., 2010; Miluzzo et al., 2008). قام الوكلاء بدمج إشارات متعددة الوسائط في تدفقات السياق المستمرة (Baltruˇsaitis et al., 2019). اعتمدت ممارسات

التخزين في هذه الفترة بشكل شائع بنية متعددة الطبقات، مع تحديد استراتيجيات التخزين حسب الاستخدام المقصود للبيانات. على سبيل المثال، قد يتم تخزين البيانات قصيرة العمر أو التي يتم الوصول إليها بشكل متكرر مؤقتا في ذاكرة الوصول السريع أو في العقد الطرفية لتقليل زمن الوصول. يمكن تخزين البيانات التي تتطلب الاحتفاظ بها على المدى المتوسط، مثل سجلات الأنشطة أو تفضيلات المستخدم، في قواعد بيانات محلية مدمجة (مثل SQLite (Hipp, 2000)، أو LevelDB أو، عندما يكون الأمان ((RocksDB (Facebook, 2013 أو ،(Ghemawat and Dean, 2014) أمرا بالغ الأهمية، ضمن وحدات التخزين الآمنة المدعومة بنظام التشغيل أو وحدات أمان الأجهزة من أجل الاستمرارية على المدى الطويل، وقابلية التوسع، والمزامنة .(Kostiainen et al., 2012) عبر الأجهزة، يمكن استخدام منصات التخزين السحابية وقواعد بيانات الخادم البعيد. في حالة وكلاء التعليمات البرمجية، قد يتم تنفيذ العديد من المهام على مدى فترات زمنية طويلة وغالبا ما تمتد إلى جلسات متعددة، مما يجعل من غير العملي الاعتماد فقط على نافذة السياق، وهي قصيرة المدى ومحدودة القدرة. لمعالجة هذه المشكلة، تقوم الأنظمة بشكل دوري بتخزين حالة المهمة والتقدم في الذاكرة طويلة المدى حتى يتمكن الوكيل من استئناف العمل بعد انقطاعه عن طريق استعادة السياق ذي الصلة. ويمكن الاحتفاظ بهذه الذاكرة طويلة المدى في قواعد بيانات محلية أو تخزين آمن، مدعومة بخدمات سحابية أو عن بعد للمزامنة عبر الأجهزة، وفي بعض الحالات، يمكن دمجها في معلمات النموذج لتوفير استمرارية أكثر استقرارا وقدرة على التكيف على المدى الطويل. على سبيل المثال، يوضح كلود كود نهجا عمليا من خلال الحفاظ على الملاحظات المنظمة، حيث تتم كتابة المعلومات الأساسية بشكل دوري من نافذة السياق إلى الذاكرة الخارجية واسترجاعها عند الحاجة. توفر هذه الإستراتيجية شكلا خفيفا من الذاكرة ولكنه مستمر، مما يسمح للوكيل بتتبع التقدم وتجنب فقدان المعلومات في المهام المعقدة. وبشكل أكثر عمومية، فقد ثبت أن هذه الآلية تدعم الأنشطة طويلة المدى، مثل إدارة الاستراتيجيات على مدى آلاف الخطوات في لعبة بوكيمون ثم الاستئناف بسلاسة بعد إعادة التعيين (Team, 2025a). بهذه الطريقة، تعمل الذاكرة الخارجية المنظمة على توسيع أفق تخطيط الوكيل إلى ما هو أبعد من حدود نافذة السياق القصيرة والعابرة.4.2 النظام البيئي للسياق على المستوى البشري SII-GAIR

4.2 النظام البيئي للسياق على المستوى البشري في العصر الثالث، تحقق أنظمة الذكاء الاصطناعي وعيا سياقيا ينافس الإدراك البشري. وقد يقومون بجمع المعلومات اللمسية بسلاسة (مثل الملمس والضغط ودرجة الحرارة)، مما يعيد إنشاء التجربة الحسية باللمسة البشرية. ومن خلال الرائحة والذوق، يقومون بتفسير الظروف البيئية، والكشف عن الدخان كإشارة خطر أو تقييم نضارة الطعام. بالإضافة إلى ذلك، فإنها تلتقط النية والعاطفة من النغمات الصوتية، والتوقفات، والتواصل البصري، وحتى الصمت، وفهم السياقات الاجتماعية الدقيقة التي تحدد التفاعل البشري. تعمل الأنظمة ذات الذكاء البشري على توحيد السياق في ذاكرة رقمية شخصية طويلة المدى. لم يعد التخزين يقتصر على الحفاظ على البيانات فحسب، بل أصبح بمثابة بنية تحتية معرفية ديناميكية: قادرة على تنظيم السياق وتحسينه بشكل مستقل لدعم التفكير المستمر والتفاعل عبر السيناريوهات وبمرور الوقت، " الشبيهة بالبشر. تتدفق البيانات بشكل آمن بين"الاستدعاء"" والنسيان"فضلا عن تحقيق قدرات " البيئات المحلية والسحابية، مما يضمن احتفاظ المستخدمين بالسيطرة المطلقة على المعلومات الحساسة مع الاستمرار في الاستفادة من المعرفة العالمية والموارد الحسابية، مما يتيح التعايش الطبيعي بين الإنسان والآلة.

5 إدارة السياق

5.1 معالجة السياق النصي لا تقتصر هندسة السياق الفعالة على جمع السياق الخام فحسب، بل تتعلق أيضا بكيفية معالجتنا له. يشكل نهج المعالجة المصمم جيدا الأساس لكل ما يلي: التفسير والضغط والاسترجاع. فهو يسمح للأنظمة بالتركيز على ما يهم، والتعلم من التجارب السابقة، وبناء فهم مستدام طويل الأجل. يتناول هذا القسم السؤال الأساسي: كيف نعالج السياق النصي الخام للحصول على أفضل النتائج؟ بالإضافة إلى مجرد تخزين السياق الخام، مثل الحوارات متعددة المنعطفات، فإننا نفحص العديد من التصميمات شائعة الاستخدام، إلى جانب المفاضلات الخاصة بكل منها. وضع علامة على السياق باستخدام الطابع الزمني أحد التصميمات الشائعة هو إرفاق طابع زمني بكل جزء من المعلومات، مع الحفاظ على الترتيب الذي تم إنشاؤه به. تحظى هذه الطريقة بشعبية كبيرة في برامج الدردشة الآلية ومراقبة نشاط المستخدم نظرا لبساطتها وتكلفة الصيانة المنخفضة. ومع ذلك، فإن هذا النهج يعاني من عدة قيود. على الرغم من أن الطوابع الزمنية تحافظ على النظام الزمني، إلا أنها لا توفر أي بنية دلالية، مما يجعل من الصعب التقاط التبعيات طويلة المدى أو استرجاع المعلومات ذات الصلة بكفاءة. ومع تراكم التفاعلات، ينمو التسلسل خطيا، مما يؤدي إلى مشكلات قابلية التوسع في كل من التخزين والاستدلال (Li et al., 2025; Perdig˜ao, 2025). وضع علامات على السياق حسب السمات الوظيفية والدلالية ينظم هذا الأسلوب المعلومات "القرار"" والهدفالسياقية عن طريق وضع علامات واضحة على كل إدخال بدور وظيفي، مثل " ، لتسهيل تفسير كل إدخال. تتيح الأنظمة الحديثة وضع العلامات من أبعاد متعددة، بما في"الإجراء"و ذلك مستويات الأولوية ومعلومات المصدر وما إلى ذلك، وبالتالي دعم الاسترجاع وإدارة السياق بشكل أكثر كفاءة (Westh¨außer et al., 2025;

10

صفحة المصدر 11

تانغ وآخرون، 2025). على الرغم من أن هذا يساعد في توضيح معنى كل جزء من المعلومات، إلا أنه يمكن أن يكون جامدا بعض الشيء وقد يحد من التفكير الأكثر مرونة أو التوليف الإبداعي. 5.2 معالجة السياق متعدد الوسائط SII-GAIRCompression مع أزواج ضمان الجودة تعيد هذه الطريقة صياغة السياق إلى أزواج أسئلة وأجوبة متميزة لتحسين كفاءة الاسترجاع، خاصة في التطبيقات مثل محركات البحث أو الأنظمة القائمة على الأسئلة الشائعة (LlamaIndex، 2024). ومع ذلك، فإنه يعطل التدفق الأصلي للأفكار، مما يجعله أقل ملاءمة للمهام التي تتطلب فهما شاملا للسياق، مثل التلخيص أو الاستدلال (Hwang et al., 2024; Dai et al., 2025). الضغط باستخدام الملاحظات الهرمية تنظم هذه الطريقة المعلومات في بنية تشبه الشجرة، حيث تتفرع المفاهيم

العريضة إلى نقاط فرعية محددة بشكل متزايد. على الرغم من أن هذا الهيكل يساعد على تقديم الأفكار بوضوح، إلا أنه يعكس في المقام الأول كيفية تجميع المعلومات بدلا من كيفية ربط الأفكار منطقيا. غالبا ما لا يتم تمثيل العلاقات مثل السبب والنتيجة أو الدليل والاستنتاج. علاوة على ذلك، لا يصور هذا التصميم كيفية تطور الفهم بمرور الوقت، على سبيل المثال، عندما تظهر رؤى جديدة أو يتم مراجعة الأفكار الحالية (Team, 2025f; Mao et al., 2025; Liskavets et al., 2024; Che et al., 2024).

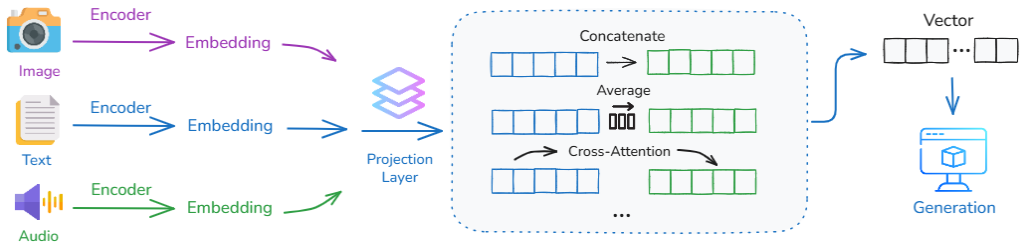

5.2 معالجة السياق متعدد الوسائط

أصبح السياق في الأنظمة المستندة إلى LLM متعدد الوسائط بشكل متزايد، بما في ذلك النصوص والصور والصوت والفيديو والتعليمات البرمجية وبيانات الاستشعار وحتى الحالات البيئية. عندما تتفاعل الآلات مع بيئات حقيقية أو محاكاة، يجب أن تكون قادرة على دمج المعلومات عبر الطرائق في تمثيل متماسك وموحد بدلا من معالجة كل طريقة على حدة. ويكمن التحدي الأساسي في عدم تجانس هذه الطرائق: فهي تختلف في البنية، وكثافة المعلومات، والديناميات الزمنية. على سبيل المثال، النص منفصل ومتسلسل؛ الصور عالية الأبعاد والمكانية. الصوت مستمر ويتكشف مع مرور الوقت. كيف يمكن تشفيرها ومقارنتها والتفكير فيها بشكل مشترك؟ في العصر 2.0، نحدد العديد من الاستراتيجيات الشائعة: الشكل 5: مثال لسير عمل لمعالجة سياق متعدد الوسائط باستخدام استراتيجيات هجينة تعيين مدخلات متعددة الوسائط إلى مساحة متجهة قابلة للمقارنة تعمل هذه الطريقة على تحويل المدخلات من طرائق مختلفة، مثل النص والصور والفيديو، إلى مساحة متجهة مشتركة، بحيث يمكن مقارنة معانيها مباشرة. تتم معالجة كل طريقة أولا بواسطة برنامج التشفير الخاص بها. نظرا لأن هذه المتجهات تعيش في البداية في مساحات تمثيل منفصلة ذات خصائص إحصائية مختلفة، يتم بعد ذلك تمرير كل منها عبر طبقة إسقاط متعلمة تقوم بتعيينها في مساحة تضمين مشتركة ذات أبعاد ثابتة. في هذا الفضاء، يتم وضع المحتوى المرتبط لغويا من طرائق مختلفة بالقرب من بعضها البعض، في حين يتم فصل المحتوى غير ذي الصلة (Peng et al., 2023; Jaegle et al., 2021; Lv et al., 2024). الجمع بين الأساليب المختلفة للاهتمام الذاتي بعد عرضها في مساحة تضمين مشتركة، تتم معالجة الرموز المميزة الخاصة بالطريقة بشكل مشترك بواسطة بنية محول واحدة. في آلية الاهتمام الذاتي الموحدة هذه، تتفاعل الرموز النصية والمرئية مع بعضها البعض في كل طبقة، مما يسمح بالمحاذاة الدقيقة والتفكير المنطقي. يمكن هذا النهج، الذي تم اعتماده من قبل ماجستير إدارة الأعمال متعدد الوسائط الحديث، النموذج من التقاط المراسلات التفصيلية، مثل العبارة التي تشير إلى أي منطقة من الصورة، بدلا من الاعتماد على التسلسل الضحل للتضمينات المستقلة (Anthropic، 2025a ؛OpenAI، 2024). استخدام طريقة واحدة للحضور إلى أخرى عبر الانتباه المتبادل تستخدم هذه الطريقة طبقات الانتباه المتبادل للسماح لطريقة واحدة (مثل النص) بالتركيز مباشرة على أجزاء محددة من طريقة أخرى (مثل الصور). بشكل ملموس، يتم استخدام ميزات إحدى الوسيلة كاستعلامات، في حين يتم التعامل مع ميزات الطريقة الأخرى كمفاتيح وقيم في آلية الاهتمام (فاسواني وآخرون، 2017). يمكن هذا الإعداد النموذج من استرداد المعلومات ذات الصلة عبر الطرائق بطريقة مستهدفة ومرنة. يمكن تنفيذ آليات الانتباه المتبادل بمرونة إما كوحدات مخصصة قبل بنية المحولات الرئيسية أو مضمنة داخل كتل المحولات نفسها، اعتمادا على التصميم العام للنظام (Yasunaga et al., 2023; Alayrac et al., 2022b). لكن،

5.3 تنظيم السياق تتطلب التصميمات التقليدية لـ SII-GAIR عادة تحديد الطرائق التي تتفاعل، في حين يمكن للعقل البشري دمج المعلومات بمرونة عبر القنوات الحسية وقنوات الذاكرة دون الاعتماد على مثل هذه التعيينات الثابتة.

5.3.1 بنية الذاكرة ذات الطبقات تعد إدارة المعلومات بشكل فعال عبر نطاقات زمنية مختلفة تحديا أساسيا في أنظمة الذكاء الاصطناعي. وكما يقول أندريه كارباثي، يمكن النظر إلى ماجستير إدارة الأعمال من خلال تشبيه نظام التشغيل: يعمل النموذج مثل وحدة المعالجة المركزية، في حين تشبه نافذة السياق ذاكرة الوصول العشوائي (RAM) - ذاكرة عاملة سريعة ولكنها محدودة السعة. تماما كما يقرر نظام التشغيل البيانات التي سيتم تحميلها في ذاكرة الوصول العشوائي (RAM)، تحدد هندسة السياق المعلومات التي يجب أن تدخل النافذة للاستدلال الفعال (langchain Research, 2025). وكما فعلنا في النظام، تستفيد بنيات الذكاء الاصطناعي من فصل الذاكرة إلى طبقات متميزة بناء على الأهمية والأهمية الزمنية. يسمح هذا النهج الهرمي للأنظمة بالحفاظ على الوصول السريع إلى المعلومات ذات الصلة مؤخرا مع الحفاظ على المعرفة القيمة في تخزين أكثر

استقرارا وطويل الأمد. على سبيل المثال، تقوم أنظمة LeadResearcher بتخزين خطط البحث في > 200 ألف رمز)، مما يمنع فقدان المعلوماتالذاكرة الدائمة عند التعامل مع سياقات طويلة جدا (الأساسية بسبب حدود نافذة السياق (Team, 2025b). الفكرة الأساسية هي أن الأنواع المختلفة من المعلومات تتطلب استراتيجيات مختلفة للاحتفاظ بها. تحتاج السياقات الحديثة إلى استرجاع سريع، ولكنها قد تصبح غير ذات صلة بسرعة، في حين يجب أن تستمر الأنماط المهمة والمعرفة المكتسبة عبر الجلسات. ومن خلال تنظيم الذاكرة بشكل هرمي، يمكن للأنظمة تحسين الاستجابة وكفاءة التخزين. يركز الإطار الذي نقدمه هنا على نموذج من طبقتين من أجل الوضوح، ولكن المبادئ تمتد بشكل طبيعي إلى بنيات أكثر تعقيدا. غالبا ما تشتمل التطبيقات الحقيقية على طبقات وسيطة إضافية، مثل الذاكرة العاملة للمعالجة النشطة، أو المخازن المؤقتة العرضية للأحداث الأخيرة، أو ذاكرات التخزين المؤقت المتخصصة لمجالات مختلفة، ولكل منها خصائصها الزمنية ومعايير الاختيار الخاصة بها (Qin et al., 2025; Stackademic, 2025).5.3 تعريف تنظيم السياق 5.1 (الذاكرة قصيرة المدى). يتم تعريف الذاكرة قصيرة المدى على أنها مجموعة فرعية من السياق ذات أهمية زمنية عالية، يتم تحديدها بواسطة وظيفة المعالجة:

حيث wtemporal (c) هي دالة وزن الأهمية الزمنية لعنصر السياق c، وθs هي عتبة الأهمية الزمنية للذاكرة قصيرة المدى، وfshort هي وظيفة معالجة قد تتضمن حكما بشريا، أو تصفية إرشادية، أو عمليات على مستوى النظام. التعريف 5.2 (الذاكرة طويلة المدى). يتم تعريف الذاكرة طويلة المدى على أنها المجموعة الفرعية المعالجة والمستخرجة من السياق ذات الأهمية العالية: Ms = fshort (c ∈C : wtemporal (c) > θs) (5)

Ml = flong (c ∈C : أهمية (c) > θl ∧wtemporal (c) ≥θs) (6)

حيث wimportance (c) هو وزن أهمية عنصر السياق c، θl هي عتبة الأهمية للذاكرة طويلة المدى، وflong هي وظيفة مركبة قد تجمع بين الاختيار والتجريد والضغط لإنشاء تمثيلات مستقرة. التعريف 5.3 (نقل الذاكرة). يتم تعريف النقل من الذاكرة قصيرة المدى إلى الذاكرة طويلة المدى على النحو التالي:

نقل: السيدة → مل (7)

تمثل وظيفة النقل هذه عملية الدمج حيث تتم معالجة المعلومات التي يتم الوصول إليها بشكل متكرر أو ذات أهمية كبيرة في الذاكرة قصيرة المدى لتصبح جزءا من الذاكرة طويلة المدى. ويخضع النقل لعوامل مثل تكرار التكرار، والأهمية العاطفية، والأهمية لهياكل المعرفة الحالية. 5.3.2 عزل السياق الوكيل الفرعي يوفر الوكيل الفرعي طريقة بديلة للتغلب على قيود السياق مع تقليل مخاطر

تلوث السياق، مما يمثل استراتيجية ناشئة لإدارة السياق الفعالة من خلال عزل السياق الوظيفي هذا المبدأ: كل وكيل فرعي هو Claude Code يوضح نظام الوكيل الفرعي .(Team، 2025a) مساعد ذكاء اصطناعي متخصص له نافذة سياق معزولة خاصة به، وموجه نظام مخصص، وأذونات أداة مقيدة. عندما تتطابق مهمة ما مع خبرة وكيل فرعي، يمكن للنظام الرئيسي تفويضها إلى تلك الوحدة، والتي تعمل بعد ذلك بشكل مستقل دون تلويث السياق الأساسي للمحادثة. يمكن تطبيق هذا المبدأ على اختيار السياق من خلال تنفيذ الفصل على طول الأبعاد الوظيفية (مثل التحليل والتنفيذ والتحقق) أو الطبقات الهرمية (مثل التخطيط والتنفيذ والمراجعة)، حيث تتلقى كل وحدة معزولة فقط الحد الأدنى من الأذونات المطلوبة لمسؤولياتها المحددة، مما يحسن موثوقية النظام وقابلية التفسير (Anthropic, 2025b). على عكس أساليب الاسترجاع الثابتة مثل RAG، يقوم أولا بوضع الخطة. إذا كانت المعلومات المتاحة غير كافية، فيمكن إصدار المزيد LeadResearcher من عمليات البحث أو ضبط الكلمات الرئيسية أو إنشاء مهام فرعية جديدة. قد يعمل الوكلاء الفرعيون بالتوازي، بينما يقوم LeadResearcher بتلخيص النتائج المؤقتة ويقرر الخطوات التالية. تساعد حلقة التغذية الراجعة هذه النظام على الوصول إلى إجابات عالية الجودة (Team, 2025b).

12

صفحة المصدر 13

المراجع خفيفة الوزن غالبا ما يعتمد عزل السياق على تخزين معلومات كبيرة خارجيا وكشف المراجع خفيفة الوزن فقط في نافذة النموذج. في نهج وضع الحماية، كما هو مستخدم في يتم تخزين المخرجات الضخمة في صندوق حماية منفصل ،HuggingFace الخاص بـ CodeAgent ولا يتم استرجاعها إلا عند الحاجة. بهذه الطريقة، يتفاعل النموذج فقط مع مراجع موجزة، بينما يحتفظ صندوق الحماية بالبيانات الكاملة ويوفرها عند الطلب. ينطبق مبدأ مماثل على كائنات الحالة المستندة إلى المخطط، حيث تظل العناصر الثقيلة مثل الملفات أو السجلات في وحدة التخزين الخارجية وتظهر الحقول المحددة فقط. يعمل كلا الأسلوبين على تقليل حمل الرمز المميز بإمكانية الوصول إلى السياق الكامل عند الحاجة (Martin, 2025).5.4 تجريد السياق SII-GAIR مع الاحتفاظ

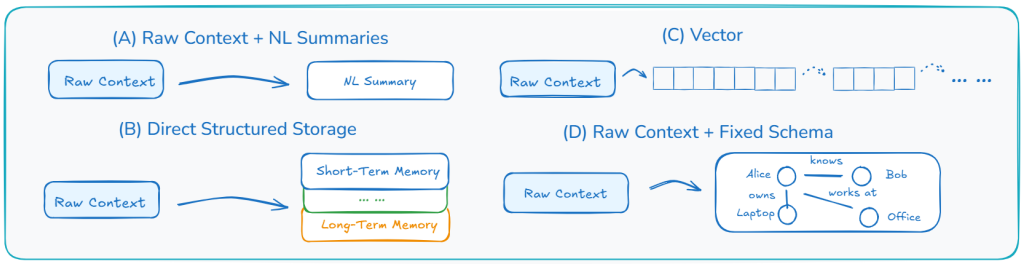

5.4 تجريد السياق

يمكن أن يتراكم السياق الأولي، مثل دورات الحوار ومخرجات الأداة والمستندات المستردة، بسرعة. إذا ترك التاريخ المتنامي دون معالجة، فإنه يمكن أن يطغى بسرعة على النظام، مما يجعل من الصعب تحديد ما هو مهم حقا للتفكير أو اتخاذ القرار في المستقبل. لإدارة ذلك، فإن القدرة الحاسمة للعوامل القابلة للتطوير هي تجريد السياق: تحويل السياق الخام إلى تمثيلات أكثر إحكاما وتنظيما. " نشير إلى هذه العملية على أنها عملية "الخبز الذاتي" بهضم حيث يقوم العامل بشكل انتقائي بهضم سياقه الخاص إلى هياكل معرفية ثابتة. وهذا يعكس العمليات المعرفية البشرية، حيث تؤدي الذكريات العرضية إلى ظهور الذاكرة الدلالية، أو حيث يتم تجريد الأفعال المتكررة إلى عادات. وفي

نهاية المطاف، فإن الخبز الذاتي هو ما يفصل بين تخزين الذاكرة والتعلم. بدون الخبز الذاتي، يتذكر الوكلاء ببساطة؛ ومعها، تتراكم المعرفة. الشكل 6: تصميمات تمثيلية للخبز الذاتي في العصر 2.0 استخدام بنيات الذاكرة الهرمية تتبنى الأنظمة الحالية عادة مبدأ معماريا: تنظيم الذاكرة الهرمي. توفر الذاكرة الهرمية طريقة مبدئية لإدارة السياقات المتنامية من خلال تنظيم المعلومات على مستويات مختلفة من التجريد. في الطبقة الأساسية، يتم تخزين السياقات الأولية لضمان إمكانية الوصول إلى التفاصيل الدقيقة. ومع زيادة حجم السياق، يتم تلخيص هذه العناصر الأولية تدريجيا إلى تمثيلات أكثر تجريدية، والتي يتم تمريرها بعد ذلك إلى الطبقة التالية. عادة ما تدخل المعلومات " تدريجيا إلى الأعلى، مما يسمح للنظام بالتوسع دونتحميصهاالجديدة من الطبقة السفلية ويتم " إرباك نافذة السياق مع الاحتفاظ بالروابط القابلة للاسترجاع مرة أخرى إلى التفاصيل الأصلية. وبهذا المعنى، فإن الذاكرة الهرمية تكمل التمييز بين الذاكرة قصيرة المدى والذاكرة طويلة المدى: يتواجد السياق الخام عادة في الذاكرة قصيرة المدى السفلية، بينما تميل التمثيلات الأكثر تجريدية إلى التوافق مع الذاكرة طويلة المدى (He et al., 2025; Patel and Singh, 2025). إضافة ملخصات باللغة الطبيعية في هذا النمط، يقوم النظام بتخزين السياق الكامل في شكله الأصلي غير المنظم. بالإضافة إلى ذلك، فإنه يقوم بشكل دوري بإنشاء ملخصات توفر رؤية مختصرة لما حدث حتى الآن. تقدم هذه الملخصات، المكتوبة عادة باللغة الطبيعية، نظرة عامة سريعة على الأحداث الأخيرة ويمكن إنشاؤها إما يدويا أو تلقائيا. على سبيل المثال، قد يقوم برنامج الدردشة الآلية بتخزين سجل الحوار الكامل وإنشاء فقرة مختصرة تلخص المحادثة الأخيرة. ومع تزايد عدد الملخصات، قد تطبق الأنظمة تلخيصا متعدد المستويات (تلخيص الملخصات القديمة في لمحات عامة ذات مستوى أعلى) أو استخدام استراتيجيات محددة لإسقاط الملخصات الأقل فائدة بناء على الوقت أو الأهمية (مارتن، 2025). تساعد هذه الملخصات النظام على التركيز على المعلومات الأساسية مع الاحتفاظ بالتفاصيل الكاملة متاحة إذا لزم الأمر. هذه الطريقة بسيطة ومرنة. ومع ذلك، نظرا لأن الملخصات مجرد نص عادي، فإنها تفتقر إلى البنية. وهذا يجعل من الصعب على النظام فهم الروابط بين الأحداث أو إجراء تفكير أعمق حول السياق (Smith and Zhang, 2025). استخراج الحقائق الأساسية باستخدام مخطط ثابت يمتد هذا النمط إلى الأول عن طريق إضافة تفسير منظم. لا يقوم النظام بتخزين السياق الأولي فحسب، بل يستخرج أيضا المعلومات الأساسية بتنسيق محدد مسبقا لتسهيل الوصول إليها والتفكير فيها. يمكن أن يتخذ المخطط أشكالا مختلفة: قد يكون عبارة عن خريطة كيان، والتي تمثل الكيانات الرئيسية (مثل الأشخاص أو العناصر أو الأماكن) كعقد. تحتفظ كل عقدة بخصائص الكيان (على سبيل المثال، الاسم والنوع)، والحالة الحالية (على سبيل المثال، يقع، ""يعمل مع، ""يمتلكالموقع، والحالة) والروابط إلى الكيانات الأخرى (على سبيل المثال، "). أو يمكن أن تكون سجلات الأحداث، والتي تعمل كقالب يقسم الحدث إلى جوانب مختلفة."في

وبالإضافة إلى ذلك، يمكن أن يكون

13

صفحة المصدر 14

6. سياق استخدام شجرة المهام SII-GAIRa، حيث يتم تقسيم الأهداف المعقدة إلى مهام فرعية في هيكل هرمي. ومن الأمثلة الملموسة على ذلك هو CodeRabbit، الذي ينشئ ملف حالة منظما قبل مراجعة التعليمات البرمجية، وترميز التبعيات عبر الملفات، ومعلومات العلاقات العامة التاريخية، والقواعد الخاصة بالفريق في مخطط واضح، مما يمكن الذكاء الاصطناعي من التفكير في سياق النظام الكامل بدلا من تغييرات الملف المعزولة (براساد، 2025). يتيح هذا النهج تفكيرا أكثر فعالية من الملخصات الأولية من خلال السماح للنظام باسترجاع حقائق محددة وتحليلها وربطها ضمن مخطط واضح. ومع ذلك، فإن الحفاظ على طبقات متعددة يمكن أن يؤدي إلى عدم الاتساق، ويظل تصميم أدوات استخراج جيدة لملء هذه المخططات بشكل موثوق يمثل تحديا كبيرا (Du et al., 2025). ضغط السياق تدريجيا إلى نواقل تلتقط المعنى بصرف النظر عن تخزين السياقات الأولية، يقوم هذا النهج بتشفير المعلومات كمتجهات رقمية كثيفة، تعرف باسم التضمينات، التي تعكس معنى الإدخال. هذه المتجهات قابلة للضغط، مما يسمح ببناء ذاكرة متعددة المستويات (هرمية) تلخص السياق على مستويات مختلفة. تخضع هذه المتجهات للخبز الذاتي، حيث يتم تلخيص التضمينات القديمة بشكل دوري في تمثيلات مدمجة (عادة من خلال التجميع)، أو دمجها مع الحالات طويلة المدى الموجودة، وإعادة تشفيرها لتكوين ذكريات دلالية أكثر تجريدا واستقرارا بشكل تدريجي. هذه الطريقة مدمجة ومرنة، وهي مفيدة بشكل خاص للبحث الدلالي أو مطابقة الاستعلامات المماثلة. ومع ذلك، فإن التمثيلات الناتجة ليست قابلة للقراءة من قبل الإنسان، مما يجعل من الصعب تحرير أو فحص أجزاء معينة من الذاكرة (Sun and Zeng, 2025; Chen and Xu, 2024).

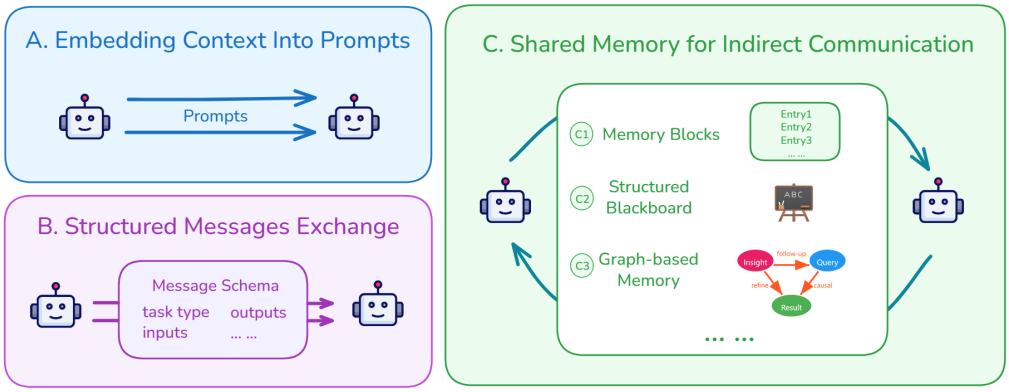

6 استخدام السياق

6.1 مشاركة السياق داخل النظام

غالبا ما تشتمل تطبيقات LLM الحديثة على وكلاء متعددين، كل منهم مسؤول عن جزء من سير عمل منطقي أكبر. أحد الأسباب العملية وراء عمل الأنظمة متعددة الوكلاء هو أنها تسمح للنظام باستهلاك المزيد من الرموز المميزة التي يمكن لوكيل واحد التعامل معها، مما يزيد بشكل فعال من قدرة العملية الإجمالية (Team, 2025b). وفي مثل هذه الأنظمة، ينشأ تحدي رئيسي: كيف يمكن لهؤلاء الوكلاء مشاركة السياق لتحقيق سلوك متماسك وتعاوني؟ على عكس مطالبة الوكيل الفردي، تتطلب الأنظمة متعددة الوكلاء طرقا واضحة ومنظمة لتمرير المعلومات بين الوكلاء. قد يقدم أحد الوكلاء إجابة جزئية أو نتيجة وسيطة، والتي يجب بعد ذلك فهمها واستخدامها من قبل شخص آخر. ولدعم ذلك، يجب أن تكون المعلومات المشتركة دقيقة وسهلة التفسير وقابلة للاستخدام مباشرة في الخطوة التالية. نحدد العديد من الأنماط الشائعة لمشاركة السياق عبر الوكلاء: الشكل 7: الأنماط الشائعة لمشاركة السياق عبر الوكلاء تضمين السياق السابق في الموجهات تقوم هذه الطريقة بتمرير

المعلومات عن طريق تضمين السياق السابق مباشرة في موجه الإدخال الخاص بالوكيل التالي. في كثير من الأحيان، يتم إعادة تنسيق المعلومات لتكون أكثر وضوحا. على سبيل المثال، قد يقوم أحد الوكلاء بتلخيص عملية التفكير الخاصة به كنص عادي، والذي يقرأه الوكيل التالي ويستمر منه. تعد هذه الطريقة لتمرير السياق شائعة في أنظمة مثل AutoGPT (Team, 2025c) وChatDev (Liu and Kumar, 2025; Qian et al., 2024)، حيث يعمل الوكلاء بالتسلسل باستخدام المطالبات كقناة اتصال خاصة بهم. تبادل الرسائل المنظمة بين الوكلاء يتواصل الوكلاء عن طريق تبادل الرسائل المنظمة باستخدام تنسيق ثابت. تتبع هذه الرسائل عادة مخططا محددا مسبقا يحتوي على حقول مثل نوع المهمة وبيانات الإدخال ونتائج المخرجات وخطوات التفكير. يقرأ الوكيل المتلقي هذه الرسالة ويواصل المهمة. تستخدم أنظمة مثل Letta (Team, 2024) وMemOS (Han et al., 2025) هذا النهج للحفاظ على الوضوح والاتساق عند تمرير المعلومات بين الوكلاء.

14

صفحة المصدر 15

غالبا ما يتواصل استخدام الذاكرة المشتركة لوكلاء الاتصال غير المباشرين بشكل غير مباشر عن طريق القراءة والكتابة في مساحة ذاكرة مشتركة، والتي يمكن تنفيذها كمخزن خارجي مركزي أو كمنطقة عامة داخل ذاكرة وكيل فردي. بدلا من إرسال الرسائل مباشرة، يترك الوكلاء المعلومات في هذه المساحة المشتركة، والتي غالبا ما يتم تنظيمها ككتل ذاكرة، ويتحققون منها لاحقا لتلقي التحديثات. يمكن لكل كتلة تخزين وحدة سياق ويتم تصنيفها عادة ببيانات التعريف الأساسية، مثل من قام بإضافتها ومتى ونوع البيانات التي تحتوي عليها. تعتمد أنظمة مثل MemGPT (Team, 2024) وA-MEM (Chen et al., 2024a) هذا النهج لدعم الاتصال والتنسيق غير المباشر بين الوكلاء. هناك طريقة أخرى وهي جعل الذاكرة أكثر تنظيما: فبدلا من وضع البيانات الأولية في مجمع " مشتركة يتم تنظيمها إلى شرائح بناء على الموضوعات أوسبورةعام، تتم كتابة المعلومات على " المهام أو الأهداف (Du et al., 2025; Salemi et al., 2025). يراقب كل وكيل فقط القطاعات ذات الصلة بخبرته ويضيف أو يعدل الإدخالات وفقا لذلك. تعمل هذه البنية المعيارية على تقليل الارتباك مع السماح للوكلاء بالتعاون بشكل غير متزامن. يمكن أيضا تنظيم الذاكرة على شكل رسم بياني. على سبيل المثال، يمثل محرك ذاكرة المهام (TME) (Ye, 2025) عملية التفكير الخاصة بالوكيل كرسم بياني للمهمة: تقوم كل عقدة بتشفير خطوة واحدة، بما في ذلك حالة الإدخال والإخراج والتنفيذ، بينما تلتقط الحواف التبعيات بين الخطوات. يمكن هذا الهيكل الوكلاء من تتبع التفكير متعدد الخطوات وإعادة استخدامه واستئنافه بطريقة موثوقة وقابلة للتفسير. وبالمثل، تقوم

بنمذجة الذاكرة كرسم بياني دلالي، حيث تمثل العقد الرؤى (Zhang et al., 2025) G-Memory واستعلامات المستخدم والنتائج الوسيطة، وتعكس الحواف العلاقات مثل المتابعة أو التنقيح أو الارتباط السببي. تتيح هذه الذاكرة المنظمة للرسم البياني تمثيلا أكثر ثراء للسياق وتفكيرا أكثر فعالية عبر خطوات أو مهام متعددة.6.2 مشاركة سياق النظام عبر SII-GAIR

في سياق البيئات متعددة الوكلاء، يمكن فهم النظام على أنه أي نظام أساسي أو نموذج أو تطبيق مستقل يحافظ على سياقه أو حالته الخاصة لأداء المهام. في حين أن الأنظمة المختلفة قد تختلف من حيث الحجم والقدرات، إلا أن كل منها يدير المعلومات ضمن حدوده الخاصة. تسمح مشاركة السياق عبر الأنظمة لهذه الكيانات المتميزة بالوصول إلى المعلومات ذات الصلة أو تبادلها، مما يتيح تنسيقا أو تفكيرا أفضل. على سبيل المثال، توضح مشاركة السياق بين Cursor وChatGPT هذا النوع من التفاعل عبر الأنظمة. عندما تتم مشاركة السياق داخل نظام واحد، يكون الأمر أسهل بشكل عام لأن المكونات مصممة للتشغيل المتبادل - فهي تستخدم في الغالب تنسيقات بيانات متوافقة، وتتبع

قواعد مماثلة، وتتوقع أنواعا مماثلة من المدخلات والمخرجات. ونتيجة لذلك، يمكن في كثير من الأحيان تبادل السياق دون ترجمة واسعة النطاق. في المقابل، عند مشاركة السياق عبر أنظمة مختلفة، قد يستخدم كل نظام تنسيقه وبنيته ومنطقه الخاص. ما هو منطقي في نظام ما قد يبدو غير مألوف تماما لنظام آخر. في هذه الحالة، يتمثل التحدي في جعل السياق المشترك قابلا للتفسير عبر الحدود. 6.2 مشاركة السياق عبر الأنظمة استخدم المحولات لتحويل السياق يستمر كل نظام في استخدام التنسيق الخاص به ويضيف محولا لترجمة السياق إلى شيء يمكن للنظام الآخر قراءته. وهذا يمنح الأنظمة مزيدا من الحرية، ولكنه يعني أنه يتعين عليك إنشاء محول منفصل لكل اتصال استخدام التمثيل المشترك عبر الأنظمة توافق .(Zarabzadeh et al., 2024; David, 2024) جميع الأنظمة على استخدام نفس التمثيل منذ البداية، مما يضمن قدرة كل منها على القراءة والكتابة مباشرة. وهذا يتجنب الحاجة إلى الترجمة بين كل زوج من الأنظمة ويجعل التكامل أسهل بكثير يمكن أن تتخذ التمثيلات المشتركة أشكالا مختلفة. تتضمن .(Team, 2025e; Gupta, 2025) الأساليب الشائعة ما يلي: استخدام تنسيق بيانات مشترك مثل JSON أو API يمكن أن تتفق الأنظمة على تنسيق ثابت للسياق، مثل مخطط JSON مشترك أو واجهة برمجة تطبيقات محددة جيدا. وهذا يسمح لكل نظام بقراءة وكتابة السياق بطريقة متسقة، وتجنب الحاجة إلى منطق ترجمة مخصص (Anderson, 2025; Sahu, 2025). مشاركة السياق عبر ملخصات يمكن قراءتها بواسطة الإنسان بدلا من الاعتماد على هياكل البيانات الرسمية، يمكن للأنظمة تبادل أوصاف قصيرة للغة الطبيعية. من السهل على البشر فهم هذه الملخصات ويمكن أيضا تفسيرها بواسطة نماذج اللغة عند الحاجة (Dobre et al., 2025; Team, 2025i). تمثيل السياق كمتجهات دلالية يمكن أيضا تمثيل السياق كمتجهات رقمية تلتقط معنى المعلومات. هذه الطريقة مرنة ومستقلة عن النظام، ولكنها تتطلب غالبا نماذج التعلم الآلي لتفسيرها بشكل صحيح (Raj, 2025; Team, 2025d; Petrova et al., 2025). كل طريقة تنطوي على المقايضات. توفر المخططات القياسية الدقة، ولكنها تتطلب تنسيقا صارما. اللغة الطبيعية مرنة وسهلة الإنشاء، ولكن من الصعب تحليلها بشكل موثوق. المتجهات الدلالية مدمجة وقابلة للتعميم، ولكنها أقل قابلية للتفسير. يعتمد الاختيار الأفضل على الأنظمة المعنية وأهداف الاتصال.

6.3 اختيار السياق للفهم حتى مع نوافذ السياق الموسعة، تظل LLM تعاني من عنق الزجاجة بسبب جودة رموز الإدخال التي يمكن أن تعتمد عليها. لذا يبرز سؤال مهم: ما هي المجموعة الفرعية من السياق المتاح التي ينبغي اختيارها للخطوة الحالية؟

قد تنشأ السياقات من لوحة مسودة، أو من الذاكرة، أو من تعريفات الأدوات، أو من المعرفة المستردة عبر RAG، ولكن ليست كل السياقات مفيدة بنفس القدر (Martin, 2025). يمكن أن تؤدي أجزاء الذاكرة غير ذات الصلة أو المزعجة إلى تشتيت التفكير أو زيادة تكلفة الاستدلال. من الناحية التجريبية، غالبا ما ينخفض أداء ترميز الذكاء الاصطناعي عندما تتجاوز نوافذ السياق نسبة الامتلاء بنسبة 50% تقريبا، مما يشير إلى أن السياق المفرط وغير الكافي يمكن أن يؤدي إلى انخفاض الفعالية (Osmani, 2025). بدون تصفية قوية، يخاطر العملاء بالإرهاق من ذاكرتهم الخاصة، وهو . وبالتالي، يصبح الاختيار الفعال للسياق شكلا من أشكال"الحمل الزائد للسياقشكل حديث من " الاهتمام قبل الاهتمام، أي اختيار ما يستحق الاهتمام. مع ظهور الوكلاء المعتمدين على LLM، تحول عصر هندسة السياق 2.0 نحو التفاعل الديناميكي الموجه نحو الهدف. أصبحت تصفية السياق عملية تكيفية، حيث يتم الاختيار الديناميكي للمعلومات الأكثر صلة بالقصد الحالي للمستخدم (Smith and Zhang, 2025; Patel and Singh, 2025). نحدد العديد من العوامل التي يجب أخذها في الاعتبار أثناء اختيار الذاكرة: 6.3 اختيار السياق لفهم الصلة الدلالية لـ SII-GAIR يشير إلى تحديد إدخالات الذاكرة الأكثر تشابها في المعنى مع الاستعلام أو الهدف الحالي. يتم تنفيذ ذلك عادة عبر الاسترجاع القائم على المتجهات: يتم تشفير كل من إدخالات الاستعلام والمرشح على شكل تضمينات كثيفة، ويقوم البحث عن الجار الأقرب (على سبيل المثال، FAISS أو طرق الجار الأقرب التقريبية الأخرى) باسترداد العناصر عن طريق التشابه، مما يسمح بالعثور على العناصر ذات الصلة لغويا حتى بدون تطابق تام للكلمات الرئيسية (Johnson et al., 2019). يستخدم هذا النهج بشكل شائع في خطوط أنابيب وأنظمة الجيل المعزز للاسترجاع (RAG) مثل Letta (Team, 2024; Chen and Xu, 2024; Sun and Zeng, 2025). التبعية المنطقية تشير التبعية المنطقية إلى الحالات التي تعتمد فيها المهمة الحالية بشكل مباشر على المعلومات التي تنتجها الخطوات السابقة، مثل قرارات التخطيط المسبق، أو مخرجات الأدوات، أو سلاسل الاستدلال. تعالج أنظمة مثل هذه المشكلة عن طريق تسجيل آثار الاستدلال بشكل واضح أثناء التنفيذ: كلما تم إنشاء MEM1 خطوة جديدة، يقوم MEM1 بتخزينها في فتحة الذاكرة وربطها بالخطوات السابقة التي تعتمد عليها (على سبيل المثال، التحليلات السابقة أو مخرجات الأداة). وبمرور الوقت، يشكل هذا رسما بيانيا منظما للتبعية عبر إدخالات الذاكرة. عند ظهور استعلام جديد، يمكن لـ MEM1 اجتياز هذا الرسم البياني لاسترداد السياق الذي يكمن في سلسلة التبعية ذات الصلة فقط، مما يضمن أن الذاكرة لا تعكس فقط الأهمية السطحية ولكن أيضا التدفق المنطقي للمهمة (Xu et al., 2025; Li and Garcia, 2024; Zhao and Kim, 2025). غالبا ما تكون عناصر الحداثة والتكرار التي تم استخدامها مؤخرا أو تم الوصول إليها أكثر عرضة للاسترداد مرة أخرى. يعتمد هذا على استدلالات بسيطة: إذا كان هناك شيء مفيد من قبل، فقد يكون مفيدا مرة أخرى. ولتنفيذ ذلك، تقوم الأنظمة

عادة بتعيين أولوية أعلى لإدخالات الذاكرة الأحدث وتخفض تدريجيا أولوية الإدخالات القديمة، بحيث تصبح المعلومات القديمة بطبيعة الحال أقل تأثيرا. وفي الوقت نفسه، تكتسب الإدخالات التي يتم الوصول إليها بشكل متكرر أهمية أكبر، مما يضمن بقاء المعلومات المرجعية الشائعة متاحة بسهولة. ومن خلال موازنة هذه العوامل، يتطور مجمع الذاكرة لصالح السياقات الجديدة والمهمة (Team, 2024; Patel and Singh, 2025). المعلومات المتداخلة إذا كانت أجزاء متعددة من المعلومات تنقل نفس المعنى، فيمكن تصفية المعلومات الأقدم أو الأقل تفصيلا (Du et al., 2025; Jiao et al., 2024). في الأنظمة الحديثة، يتم التعامل مع هذه العملية بشكل متزايد من خلال إدارة الذاكرة النشطة، حيث لا يقوم النظام باكتشاف التشابه بشكل سلبي فحسب، بل يقرر بشكل فعال متى يتم دمج أو تحديث أو إزالة الإدخالات الزائدة للحفاظ على مجموعة ذاكرة موجزة وذات صلة (يون وآخرون، 2025). تفضيلات المستخدم وملاحظاته بمرور الوقت، يمكن لوكلاء الذكاء الاصطناعي التكيف مع عادات المستخدم: معرفة أنواع المعلومات التي يميل المستخدم إلى تقديرها. تقوم بعض الأنظمة، مثل ذاكرة التطور الذاتي (Jin et al., 2024; Zhao and Kim, 2025)، بتتبع كيفية تفاعل المستخدمين مع المعلومات واستخدامها لضبط أهمية أو وزن إدخالات الذاكرة. الاعتبار الأساسي في اختيار الذاكرة هو الملاءمة. ويمكن تقييم ذلك من خلال عدة عوامل، بما في ذلك التشابه الدلالي، والتبعية المنطقية، والحداثة (توقيت المعلومات)، وتكرار الذكر. على سبيل المثال، تستخدم العديد من الأنظمة درجات التشابه لمقارنة المدخلات الحالية مع المحتوى المخزن، مما يؤدي إلى تعيين صلة أعلى بالمعلومات ذات التشابه الأكبر. وبدلا من ذلك، يمكن دمج علامات واضحة أو بيانات وصفية للإشارة إلى أهمية أو وظيفة بيانات محددة، مثل وضع علامة على أحداث معينة كمعالم رئيسية أو تسليط الضوء على الحقائق الأساسية. بالإضافة إلى الملاءمة، من المهم تقليل المعلومات الزائدة عن الحاجة والتكيف مع عادات المستخدم. ومن خلال دمج هذه المعايير، تكون الأنظمة قادرة على الاحتفاظ بالبيانات الأكثر صلة، وتقليل الضوضاء غير الضرورية، وتعزيز كفاءة اختيار السياق. استراتيجيات التصفية الشائعة مع أخذ هذه العوامل في الاعتبار، تتبنى الأنظمة استراتيجيات تصفية مختلفة. في خطوط أنابيب RAG، تتمثل الخطوة الأولى في تقسيم المصدر إلى أجزاء يمكن التحكم فيها، وهو ما يمكن القيام به باستخدام استراتيجيات بسيطة مثل الخط الثابت أو نوافذ الرمز المميز، أو باستخدام أساليب أكثر تنظيما مثل التجزئة المستندة إلى AST التي تحترم حدود الوظيفة أو الفئة أو الوحدة وتحافظ على التماسك الدلالي. ومن ثم تتم عملية الاسترجاع بعدة طرق مختلفة. غالبا ما يعتمد الاسترجاع الدلالي على البحث القائم على التضمين، والذي يختار الأجزاء وفقا لتشابه المتجهات مع الاستعلام (Chen and Xu, 2024). يمكن أن يكون الاسترجاع غير الدلالي مباشرا مثل

16

صفحة المصدر 17

6.4 يحتاج المستخدم الاستباقي إلى الاستدلال SII-GAIRGrep، الذي يستخدم سلسلة أو مطابقة دون تفسير المعنى. يستخدم الاسترجاع المنظم الرسوم البيانية المعرفية، بالاعتماد على regex الكيانات وعلاقات التبعية (على سبيل المثال، الرسوم البيانية لاستدعاء الوظائف) لربط المعلومات عبر الملفات والوحدات النمطية (وين وآخرون، 2025). نظرا لأن هذه الأساليب كثيرا ما ترجع مرشحات متداخلة أو مزعجة، فإن العديد من الأنظمة تقدم مرحلة إعادة تصنيف (تدعمها أحيانا لتحسين الملاءمة، واستبدال تحسينات الدقة مقابل الكفاءة، مع اختلاف التطبيقات (على LLMs سبيل المثال، Windsurf) في خيارات التصميم الخاصة بها (Mohan, 2025).

معظم الاستخدامات الحالية للسياق هي استخدامات تفاعلية، ومع ذلك غالبا ما يجد المستخدمون صعوبة (أو غير معقول) في التعبير بشكل كامل عن احتياجاتهم وتفضيلاتهم. لسد هذه الفجوة، يجب أن تعمل هندسة السياق على تمكين الوكلاء من التصرف بشكل استباقي: لاستنتاج احتياجات المستخدم الكامنة وتفضيلاته وأهدافه التي لم يتم ذكرها صراحة، وبدء تفاعلات مفيدة وفقا لذلك. المستخدم يفضل الملخصاتوهذا مشابه للمساعدين البشريين الذين يتعلمون بمرور الوقت أن " . هذه الرؤى ليست محددة مسبقا؛ يجب"ساعات المساء هي الأفضل للعصف الذهني، أو أن ""المرئية استخراجها واستخلاصها والتحقق من صحتها من خلال سياق التفاعل المتراكم. في العصر 2.0، نحدد عدة أشكال شائعة لاستخراج التفضيلات الاستباقية: 6.4 يحتاج المستخدم الاستباقي إلى التعلم الاستدلالي والتكيف مع تفضيلات المستخدم يتعلم وكلاء الذكاء الاصطناعي الحديث ويتكيفون مع تفضيلات المستخدم في المقام الأول من خلال تحليل سجل المحادثة والبيانات الشخصية المخزنة مثل مستندات المستخدم والملاحظات والتفاعلات السابقة، من أجل تحديد أنماط أسلوب الاتصال والاهتمامات وأساليب اتخاذ القرار (Pan et al., 2025; Sun et al., 2024). في العديد من الحالات، يتم دمج هذه الرؤى في ملفات تعريف المستخدمين المتطورة التي توجه التفاعلات الأكثر

تخصيصا. ويتعلمون أيضا من الإشارات غير المباشرة من خلال ملاحظة كيفية استجابة المستخدمين للاقتراحات، وما إذا كانوا يواصلون المحادثات، ورضاهم الواضح عن المهام المكتملة، ودمج هذه الملاحظات في التفاعلات المستقبلية (OpenAI، 2024). بالإضافة إلى ذلك، في بعض الأحيان، يستكشف الوكلاء التفضيلات بنشاط من خلال سؤال المستخدمين مباشرة عما يحبونه وما لا يعجبهم أو تقديم خيارات متعددة أثناء المحادثات لجمع تعليقات صريحة (Ryu et al., 2025). استنتاج الأهداف المخفية من الأسئلة ذات الصلة يمكن للنظام استنتاج الأهداف المخفية من خلال تحليل تسلسل استعلامات المستخدم. على سبيل المثال، إذا سأل المستخدم عن أدوات تزيين Python ثم عن ضبط الأداء، فقد يعكس ذلك هدفا أوسع يتمثل في تحسين كفاءة تصميم البرامج. لدعم هذا الاستدلال، يمكن للأنظمة تشفير السياق الحالي ووضعه في ماجستير إدارة الأعمال للتنبؤ باحتياجات المستخدمين المحتملة (Anthropic, 2025a). علاوة على ذلك، فإن تقنيات التفكير المتسلسل تمكن الأنظمة من إجراء استنتاج منطقي متعدد الخطوات، واستنتاج النوايا العميقة من مدخلات المستخدم على المستوى السطحي (Yao et al., 2025). ومن خلال التعرف على هذه الأنماط، يمكن للنظام تقديم المزيد من المساعدة المتوافقة مع الأهداف. تقديم المساعدة بشكل استباقي بناء على معاناة المستخدم يكتشف النظام متى قد يكون المستخدم عالقا، مثل إظهار التردد أو تجربة العديد من البدائل، ويقدم بشكل استباقي أدوات مفيدة مثل المرئيات أو قوائم المراجعة (Chen et al., 2025). تهدف هذه التدخلات إلى تحسين جودة القرار دون سؤال المستخدم.

كما هو مذكور في الملخص، يتشكل الأفراد بشكل أساسي من خلال تفاعلاتهم مع الكيانات الأخرى - وبعبارة أخرى، من خلال سياقاتهم. ونظرا لهذا التحول، ينشأ التحدي الرئيسي بطبيعة الحال: بمجرد أن يتخذ السياق شكلا مدى الحياة، فكيف ينبغي الحفاظ عليه وتحديثه بطريقة تظل متماسكة وقابلة للتكيف وقابلة للاستخدام لكل من البشر والآلات؟ يتطلب الحفظ والتحديث المستمر للسياق مدى الحياة أكثر من مجرد تخزين قابل للتطوير: فهو يتطلب تصميم نظام ذاكرة ديناميكي وقوي من الناحية الدلالية وواعي مؤقتا. وهذا يثير تحديا تقنيا متعدد الأوجه، حيث تنهار الامتدادات الساذجة لبنيات الذاكرة الحالية تحت نطاق وسيولة وتعقيد سياق العالم الحقيقي. إليكم القصة: عندما تصبح " هندسة سياق مدى الحياة، تنشأ مشكلة: كيفية تنفيذ آليات تخزين موثوقةالعاديةهندسة السياق " تحافظ على الاتساق الدلالي؟ علاوة على ذلك، فإن مجرد التخزين غير كاف؛ ومع توسع البيانات إلى أحجام هائلة، يجب أن يكون النظام قادرا على معالجة هذه المعلومات وإدارتها بدقة. بمجرد اقتراح تصميم جديد، يصبح إطار التقييم الشامل ضروريا للتحقق من صحته وأدائه. ومع ذلك، لا تزال هذه الآليات متخلفة إلى حد كبير. بمجرد إنشاء خط الأنابيب بالكامل، يصبح الحفاظ على استقراره أمرا بالغ الأهمية. تمثل كل مرحلة ضمن سير العمل تحديات مميزة، لا سيما في مجال أنظمة السياق مدى

الحياة. 6.5 الحفاظ على السياق مدى الحياة وتحديثه التحدي الأول: اختناقات التخزين التحدي الأول هو كيفية الاحتفاظ بأكبر قدر ممكن من السياق ذي الصلة في ظل قيود صارمة على الموارد. نحن نفتقر حاليا إلى حل موحد: كيف يمكننا الحفاظ على أكبر قدر ممكن من السياق، مما يضمن إمكانية الاحتفاظ بجميع السياقات الخاصة بي بشكل فعال دون فقدان؟ ما هو نوع البنية التحتية أو الواجهة التي من شأنها تسهيل تسجيل سياقنا إلى أقصى حد؟ وكيف يمكن لأنظمة التخزين أن تدعم في نفس الوقت الضغط العالي والاسترجاع عالي الدقة والوصول بزمن وصول منخفض على نطاق واسع (Xing et al., 2025; Ahn, 2025)؟

17

صفحة المصدر 18

6.6 الممارسات الهندسية الناشئة التحدي الثاني SII-GAIR: تدهور المعالجة ينشأ تحد آخر من انهيار آليات الانتباه على نطاق واسع. تعتمد معظم النماذج القائمة على المحولات على الاهتمام العالمي، الذي يؤدي تعقيد O (n2) إلى زيادة سريعة في زمن الوصول للاستدلال، واستخدام ذاكرة العالية، وإنتاجية الإدخال/الإخراج الأبطأ. تجعل اختناقات الموارد هذه من غير العملي GPU التعامل مع السياقات الكبيرة في الوقت الفعلي. وفي الوقت نفسه، تتدهور جودة التفكير. عندما يصبح الاهتمام أقل عبر المدخلات الأطول، فإن النموذج يكافح من أجل الحفاظ على التركيز على المعلومات ذات الصلة، ويكافح من أجل التقاط التبعيات بعيدة المدى (Thai et al., 2023; Rabe and Staats, 2022). بالإضافة إلى ذلك، تصبح أنظمة الاسترجاع غارقة في العديد من المعلومات المتشابهة لغويا ولكن غير ذات صلة، وغالبا ما تعيد الانحرافات بدلا من الأدلة المفيدة (Jeong et al., 2024). علاوة على ذلك، مع نمو حجم السياق، يصبح من الصعب اكتشاف التناقضات والصراعات بين الأجزاء المستردة والتوفيق بينها. كل هذه القضايا تؤدي إلى تفكير هش عند التعامل مع سياقات كبيرة جدا. التحدي الثالث: عدم استقرار النظام مع تراكم الذاكرة بمرور الوقت، حتى الأخطاء الصغيرة يمكن أن تؤثر على أجزاء أكثر من النظام. الأخطاء التي كان لها تأثير محدود في السابق قد تنتشر الآن على نطاق واسع، مما يؤدي إلى سلوك غير متوقع أو غير مستقر. وبدون حدود واضحة أو آليات للتحقق، تصبح إدارة النظام أكثر صعوبة، خاصة في المهام التي تستمر لفترة طويلة أو تتطلب درجة عالية من الأمان. في مثل هذه الحالات، قد يجعل النظام أكثر هشاشة بدلا من زيادة الموثوقية (Meng et al., 2025; Jacobs, 2025). التحدي الرابع: صعوبة التقييم مع تراكم الذاكرة، يصبح من الصعب معرفة ما إذا كان النظام يفكر بشكل صحيح. تختبر معظم المعايير اليوم فقط ما إذا كان النظام قادرا على استرداد المعلومات، ولكنها لا تتحقق مما إذا كانت المعلومات لا

تزال ذات صلة أو دقيقة أو مفيدة. نادرا ما تتضمن الأنظمة ميزات للتحقق من التناقضات، أو التراجع عن التحديثات الخاطئة، أو تتبع خطوات التفكير التي أدت إلى الاستنتاج. وبما أن المزيد من القرارات تعتمد على سلاسل ذاكرة أطول، يصبح من الصعب بشكل متزايد فحص كيفية وصول النظام إلى إجابة محددة. هذا النقص في الرؤية يجعل من الصعب الثقة في النظام أو تحسينه، خاصة بالنسبة لهندسة السياق مدى الحياة (Zheng et al., 2025). نحو نظام تشغيل دلالي للسياق لم يعد من " أوتوسيع نافذة السياقالممكن معالجة التحدي المتمثل في هندسة السياق مدى الحياة بمجرد " . فهو يتطلب بناء نظام تشغيل دلالي قادر على النمو بمرور الوقت، مثل"تحسين دقة الاسترجاع" العقل البشري إلى حد كبير. فمن ناحية، يجب أن يدعم مثل هذا النظام التخزين الدلالي الفعال وواسع النطاق باعتباره بنك الذاكرة الخاص به، وأن يظهر قدرات إدارة الذاكرة الشبيهة بالإنسان حقا: إضافة المعرفة وتعديلها ونسيانها بشكل فعال. من ناحية أخرى، فإنه يدعو إلى معماريات جديدة لتحل محل النمذجة الزمنية المسطحة للمحولات، وبالتالي تمكين التفكير السياقي طويل المدى والتكيف الديناميكي بشكل أكثر قوة. ومن الأهمية بمكان أن يكون النظام قادرا على شرح نفسه من خلال تتبع وتصحيح وتفسير كل خطوة في سلسلة المنطق الخاصة به، وبالتالي تحسين الثقة والموثوقية في السيناريوهات العملية والحرجة للسلامة. يسلط هذا النهج الضوء على مبدأ أساسي في هندسة السياق ويعكس نقلة نوعية: لم يعد السياق متراكما بشكل سلبي، بل تتم إدارته وتطويره بشكل نشط كعنصر أساسي للإدراك.

التخزين المؤقت لـ KV في ظل الممارسات الهندسية الناشئة، أصبح استخدام التخزين المؤقت للقيمة الرئيسية (KV) أمرا أساسيا للنشر الفعال للوكلاء. يعمل التخزين المؤقت لـ KV عن طريق تخزين حالات الاهتمام (المفاتيح والقيم) للرموز المميزة السابقة بحيث لا تحتاج إلى إعادة حسابها عند إنشاء رموز مميزة جديدة. ونتيجة لذلك، يؤثر معدل الوصول إلى ذاكرة التخزين المؤقت بقوة على كل من زمن الوصول والتكلفة. لتحسين معدل الإصابة، أثبتت العديد من الممارسات أنها ضرورية: أولا، الحفاظ على استقرار المطالبات البادئة، حيث أن الاختلافات البسيطة مثل الطوابع الزمنية في بداية مطالبة النظام يمكن أن تؤدي إلى إبطال ذاكرة التخزين المؤقت بأكملها؛ ثانيا، فرض التحديثات الحتمية والإلحاقية فقط، لأن تغيير المحتوى السابق أو تسلسله بشكل غير متسق يؤدي إلى انقطاع إعادة الاستخدام؛ وثالثا، في الحالات التي لا تدعم فيها أطر الخدمة التخزين المؤقت التلقائي للبادئة التزايدية، فمن الضروري إدراج نقاط فحص ذاكرة التخزين المؤقت يدويا ووضعها بعناية (Manus, 2025). بالإضافة إلى ذلك، غالبا ما يتم استخدام عملية إحماء ذاكرة التخزين المؤقت لزيادة تعزيز الكفاءة. النهج الشائع هو التحميل التنبؤي (الجلب المسبق أو التحميل التخميني)، حيث يتوقع النظام السياقات التي من المحتمل أن تكون مطلوبة بعد ذلك

ويقوم بتحميلها في ذاكرة التخزين المؤقت مقدما (فريدمان، 2025). تظهر هذه التقنيات أن الكفاءة يتم تحديدها بشكل متزايد من خلال الطريقة التي تتم بها إدارة السياق. 6.6 تصميم أدوات الممارسات الهندسية الناشئة إن العوامل المهمة في تصميم الأداة هي الوصف والحجم. وللوصف، تحتاج الأدوات إلى أغراض دقيقة وتعريفات واضحة. غالبا ما تتسبب الأوصاف الغامضة أو المتداخلة في حدوث حالات فشل، في حين أن الأوصاف جيدة التنظيم تقلل من الغموض وتحسن الموثوقية. يمكن للنماذج أيضا تحسين هذه الأوصاف والعمل كمهندسين سريعين، مما يتيح التحسين الذاتي ،بالنسبة للحجم، فإن مجموعات الأدوات الكبيرة تجعل الوكلاء أقل موثوقية .(Team, 2025b) وغالبا ما يؤدي تحميل الأدوات ديناميكيا أثناء التفاعل إلى كسر اتساق ذاكرة التخزين المؤقت KV ويخلط بين الإشارات إلى الإجراءات السابقة. تشير الملاحظات التجريبية إلى أن مجموعات الأدوات الكبيرة بشكل مفرط يمكن أن تؤدي إلى انخفاض الأداء، حيث أن أوصاف الأدوات المتداخلة وزيادة تعقيد الاختيار يجعل اختيار الأداة الصحيحة أكثر صعوبة. بالنسبة لـ DeepSeek-v3، انخفض الأداء إلى ما بعد 30 أداة وكان من المؤكد تقريبا الفشل بعد 100 أداة (Dbreunig, 2025). هناك نهج أكثر قوة يتمثل في الحفاظ على استقرار قائمة الأدوات وفرض القيود على مستوى فك التشفير، على سبيل المثال، عن طريق الإخفاء

18

صفحة المصدر 19

7. تقوم تطبيقات SII-GAIRtoken بتسجيل الدخول لمنع الاختيارات غير الصالحة. تحافظ هذه الممارسة على الكفاءة مع تقليل الأخطاء الناتجة عن تغيير مساحة العمل (Manus, 2025). محتويات السياق لا ينبغي للوكيل إخفاء أخطاء الوكيل؛ إن الاحتفاظ بالأخطاء في السياق يسمح للنموذج بملاحظة إخفاقاته، وهو أمر بالغ الأهمية لتعلم السلوك التصحيحي وتحسين الأداء العام (مانوس، 2025). في إعدادات الوكيل، قد تؤدي المطالبة التقليدية بالطلقات القليلة إلى نتائج عكسية. عندما يحتوي السياق على أزواج عمل وملاحظة سابقة متشابهة إلى حد كبير، يميل النموذج إلى تكرار الإجراءات السابقة، وذلك ببساطة باتباع الأنماط التي يراها. وللتخفيف من ذلك، يقدم مانوس اختلافات صغيرة ومنظمة في الإجراءات والملاحظات، مثل قوالب التسلسل البديلة، أو الصياغة المتنوعة، أو التغييرات الدقيقة في الترتيب والتنسيق. تعمل هذه الاضطرابات الخاضعة للرقابة على كسر الأنماط المتكررة وتساعد في إعادة تركيز انتباه النموذج وتحسين المتانة وتقليل خطر الإفراط في التعميم (Manus, 2025). تشير تجربة أنظمة الوكلاء المتعددين إلى أن العمل الفعال متعدد الوكلاء يعتمد على عدد قليل من الممارسات المتكررة. يقوم الوكيل الرئيسي، أو

الباحث الرئيسي، بتقسيم الاستعلامات إلى مهام فرعية وتعيينها بأهداف ومخرجات وتوجيهات وحدود واضحة، حيث تؤدي التعليمات الغامضة إلى ارتباك أو ثغرات. نظرا لأن الوكلاء يواجهون صعوبة في الحكم على عبء العمل، يمكن أن تتضمن المطالبات قواعد تعديل بسيطة ذات صلة بتعقيد الاستعلام، على سبيل المثال، قد تحتاج المهام البسيطة إلى وكيل واحد لإكمالها، بينما قد تحتاج المهام الأصعب إلى المزيد. تعمل استراتيجيات البحث بشكل أفضل عندما تنتقل من الاستكشاف الواسع إلى التحليل المركز، ونمط التفكير الممتد، حيث يقوم الوكلاء بتدوين عملية التفكير الخاصة بهم بشكل واضح، مما يعزز الدقة والكفاءة الشاملة (Team، 2025b). الحيل عند تنفيذ المهام المعقدة، تحتفظ العديد من الأنظمة بملف todo.md يسرد الأهداف الفرعية، ويقوم بتحديثه ووضع علامة على العناصر كمكتملة مع تقدم المهمة. ومع ذلك، يمكن أن تفقد النماذج مسار الأهداف السابقة في المهام الطويلة. الحل العملي هو قراءة هذه الأهداف باللغة الطبيعية عند تحديث قائمة المهام، ودمجها في السياق الحديث للنموذج لإبقاء الأهداف الرئيسية ضمن اهتمامه المباشر (Manus, 2025).

7 تطبيقات

عند استخدام وكيل الذكاء الاصطناعي، غالبا ما يحتاج المطورون إلى دعم سياق مستدام وموجه نحو المشروع. تقدم Gemini CLI من Google حالة تمثيلية لكيفية هندسة السياق. الآلية المركزية هي ملف GEMINI.md، وهو عبارة عن مواصفات Markdown التي تسجل خلفية المشروع، وتعريفات الأدوار، والأدوات والتبعيات المطلوبة، واتفاقيات الترميز، وما إلى ذلك. ويتم تنظيم السياقات من خلال التسلسل الهرمي لنظام الملفات: يمكن أن توجد ملفات GEMINI.md في الدليل الرئيسي للمستخدم، أو في جذر المشروع، أو داخل الدلائل الفرعية، مما يتيح وراثة المعلومات وعزلها (philschmid, 2025). للتجميع، تجمع واجهة سطر الأوامر (CLI) نوعين من السياق: عند بدء التشغيل، تقوم تلقائيا بتحميل المعلومات الثابتة مثل مطالبات النظام، وبيئة المشروع الحالية، وملفات GEMINI.md الأصلية أو التابعة؛ أثناء التفاعل، يقوم بشكل متزايد بتجميع السياق الديناميكي من تاريخ الحوار المستمر (Irani, 2025c; Lin et al., 2025). بالنسبة للإدارة، يعمل نظام الملفات نفسه كقاعدة بيانات خفيفة الوزن، مع آليات لضغط السياق عن طريق استبدال تواريخ التفاعل الطويلة بملخصات تم إنشاؤها بواسطة الذكاء الاصطناعي. تتبع هذه الملخصات تنسيقات محددة مسبقا تحافظ على الجوانب الرئيسية للحوار (على سبيل المثال، الهدف العام والمعرفة الأساسية وحالة نظام الملفات والإجراءات الأخيرة والخطة الحالية)، مما يضمن الاتساق. اقترحت المناقشات المجتمعية أيضا توسيع هذه العملية مع التحسين البشري لدعم الإدارة التعاونية للسياق (Irani, 2025b,a; Xiao et al., 2025).7.1 CLI

يهدف وكلاء البحث العميق إلى مساعدة المستخدمين في التعامل مع الاستفسارات المفتوحة كثيفة المعرفة، مثل مهام الاستدلال التي تتضمن أحداثا متعددة وعلاقات متشابكة. ومن الأمثلة التمثيلية على ذلك Tongyi DeepResearch، الذي يعمل في أربع خطوات رئيسية: فهو يبحث في الويب بناء على استعلام المستخدم، ويستخرج المعلومات الأساسية من الصفحات ذات الصلة، ويولد أسئلة فرعية جديدة لتوجيه المزيد من البحث، وأخيرا يدمج الأدلة من مصادر متعددة في إجابات متماسكة وتستمر هذه الدورة في كثير من الأحيان لعدة جولات حتى يتم تقليل عدم .(Team, 2025h) اليقين وتشكيل سلسلة أدلة كاملة. على عكس وكلاء المحادثة القصيرة المدى، يواجه البحث العميق التحدي المتمثل في تواريخ التفاعل الطويلة للغاية: حيث أن إلحاق جميع الملاحظات والأفكار والإجراءات بشكل مباشر يتجاوز نافذة السياق بسرعة. للتغلب على هذا القيد، تعتمد Tongyi DeepResearch هندسة السياق المنهجية. أثناء الاستكشاف، يستدعي الوكيل بشكل دوري نموذج تلخيص متخصص لضغط التاريخ المتراكم في حالة تفكير مدمجة، والتي لا تحافظ على الأدلة المهمة فحسب، بل تسلط الضوء أيضا على المعلومات المفقودة وتوجيهات الخطوة التالية. يتم بعد ذلك إرساء " المضغوطة بدلا من السجل الأولي الكامل.لقطات السياقعمليات البحث والاستدلال اللاحقة على "

وبهذه الطريقة، ينشئ النظام دورة حياة واضحة للسياق: بدءا من جمع المعلومات وتجميعها، إلى الضغط الدوري والتجريد، ثم إلى التفكير وإعادة الاستخدام بناء على الملخصات، مما يسمح له باختراق قيود السياق وتحقيق قدرات بحثية قابلة للتطوير وطويلة الأفق (وو وآخرون، 2025).7.2 البحث العميق

19

صفحة المصدر 20

7.3 واجهات الدماغ والحاسوب SII-GAIR

7.3 واجهات الدماغ والكمبيوتر توفر واجهات الدماغ والكمبيوتر (BCIs) مسارا جديدا لهندسة السياق من خلال تمكين جمع السياق الأكثر تقدما (Tang et al., 2023). على عكس الطرق التقليدية التي تعتمد على إدخال اللغة، يمكن لواجهات التواصل بين الدماغ (BCI) التقاط الإشارات العصبية مباشرة، مما يقدم ميزتين متميزتين. أولا، تسمح بجمع أبعاد سياقية أكثر ثراء، مثل مستويات الانتباه، أو الحالات العاطفية، أو العبء المعرفي - وهي العوامل التي غالبا ما يصعب ملاحظتها من خلال السلوك الخارجي وحده. ثانيا، أنها توفر طريقة أكثر ملاءمة لجمع السياق، وتقليل الحاجة إلى إجراءات المستخدم الصريحة، وتمكين المزيد من المدخلات الفورية من خلال النشاط العصبي (Liu et al., 2025; Edelman et al., 2024). على الرغم من أن التقنيات الحالية لا تقدم سوى فهم تقريبي لإشارات الدماغ وقضايا مثل الضوضاء وعدم الاستقرار لا تزال تمثل تحديات كبيرة، فإن واجهات التواصل بين الدماغ (BCIs) تسلط الضوء على الاتجاه الذي قد تتطور فيه هندسة السياق: توسيع مجموعة السياق إلى ما هو أبعد من البيئات الخارجية إلى الحالة المعرفية الداخلية للمستخدم (وو وآخرون، 2023).

على الرغم من أننا حددنا إطارا تاريخيا ومفاهيميا لهندسة السياق، إلا أنه لا يزال هناك عدد من التحديات المفتوحة. نسلط الضوء أدناه على العديد من القضايا الرئيسية ونرسم الاتجاهات المحتملة للاستكشاف المستقبلي. لا يزال جمع السياق محدودا وغير فعال. لا تزال معظم أنظمة الوكلاء الحالية تعتمد على مدخلات المستخدم الصريحة للحصول على السياق، وهو أمر مرهق وغير فعال (Zhao et al., 2024). بالإضافة إلى ذلك، لا يتمكن المستخدمون أحيانا من التعبير عن نواياهم بوضوح، مما يترك المعلومات السياقية المهمة غير محددة. يتطلب التقدم طرقا أكثر طبيعية ومتعددة الوسائط لجمع السياق، جنبا إلى جنب مع النماذج التي يمكنها استنتاج احتياجات المستخدم بشكل أفضل وملء السياقات المفقودة (Chen et al., 2024b). أحد خطوط العمل الواعدة هو واجهات الدماغ والحاسوب، والتي تهدف إلى جمع حالة المستخدم ونيته بكفاءة أكبر من التعبير الصريح. تشير مثل هذه التطورات إلى أن الأشكال الأكثر ثراء لجمع السياق قد تتغلب في النهاية على القيود المتأصلة في المدخلات المستندة إلى النص (Liu et al., 2025; Edelman et al., 2024).8 التحديات والاتجاهات المستقبلية تخزين السياق واسع النطاق وإدارته مع تراكم التفاعلات، ينمو حجم السياق وتعقيده بسرعة. يكمن التحدي الرئيسي في تحديد كيفية تخزين السياق وتنظيمه وكيفية تنظيمه

بطريقة تظل قابلة للتطوير مع دعم الاختيار والاسترجاع الفعالين. وبدون تصميم دقيق، يمكن أن يصبح السياق واسع النطاق مرهقا ويصعب استخدامه في المهام النهائية (مسعود، 2025). الفهم المحدود للنموذج للسياق لا تمتلك الأنظمة الحالية نفس المستوى من الفهم السياقي الذي يتمتع به البشر. على سبيل المثال، فإنهم يعانون من المنطق المعقد والمعلومات العلائقية في الصور (يانغ " أكبر فيجهدوآخرون، 2023). وكما هو مذكور في هذه الورقة، فإن انخفاض ذكاء الآلة يؤدي إلى " هندسة السياق. ونتيجة لذلك، فإن الكثير من السياق المتاح لم يتم فهمه أو استخدامه بشكل كامل. يجب أن يركز العمل المستقبلي على تعزيز قدرات النماذج في التفكير الدلالي، والتفسير المنطقي، والمواءمة متعددة الوسائط، مما يمكن الأنظمة من فهم السياق بشكل أفضل وتقليل الاعتماد على هندسة السياق التي يحركها الإنسان (Pan et al., 2023). اختناقات الأداء ذات السياق الطويل تظل معالجة السياقات الطويلة تحديا رئيسيا. تعاني البنى القائمة على المحولات من التعقيد التربيعي، مما يجعلها غير فعالة مع نمو السياق. لقد أدت البدائل الحديثة مثل Mamba (Gu and Dao, 2024) ومتغيراتها مثل LongMamba (Ye et al., 2025b) إلى تحسين الكفاءة وقابلية التوسع، ولكنها لا تزال تظهر نقاط ضعف في فهم السياق الطويل. على سبيل المثال، عندما يتجاوز طول الإدخال طول التدريب بكثير، أو عندما تمتد التبعيات العلائقية والمنطقية إلى السياق بأكمله. يمكن لـ LOCOST (Bronnec et al., 2024) التعامل مع مستندات تضم مئات الآلاف من الرموز المميزة، ولكنها لا تزال متخلفة عن المحولات في بعض المهام التي تتطلب تفكيرا دقيقا على مدى فترات طويلة جدا. للمضي قدما، هناك حاجة واضحة لبنيات جديدة يمكنها التعامل مع السياقات الأطول بكفاءة مع توفير فهم أقوى وأكثر موثوقية، بدلا من التعامل مع السياقات الطويلة كمدخلات موسعة فقط. اختيار السياق المناسب والمفيد لا يساهم كل السياق المتاح في المهمة المطروحة. على الرغم من أن الأنظمة الحالية تستخدم بالفعل آليات تقدير الملاءمة والتصفية، إلا أن أدائها يظل محدودا: فقد يتم تفويت الإشارات المفيدة، وغالبا ما تستمر المعلومات المزعجة أو الزائدة عن الحاجة. يتمثل الاتجاه الرئيسي للبحث في تطوير استراتيجيات اختيار سياق أكثر دقة وتكيفا تعمل باستمرار على تحسين ما يجب الاحتفاظ به أو التخلص منه أو التأكيد عليه، مما يضمن بقاء السياق المحتفظ به متوافقا بشكل وثيق مع أهداف المهمة (Chen and Xu, 2024; Mohan, 2025).

الجوهر الإنساني هو مجموعة العلاقاتالحضور الرقمي كتب كارل ماركس ذات مرة أن "
" (ماركس، 1845). وفي عصر الذكاء الاصطناعي الذي يركز على السياق، تكتسب هذهالاجتماعية الفكرة معنى حسابيا جديدا: حيث يتم تعريف الأفراد على نحو متزايد ليس من خلال وجودهم الجسدي أو نشاطهم الواعي، بل من خلال السياقات الرقمية التي يولدونها: محادثاتهم، وقراراتهم، وآثار تفاعلهم. يمكن لهذه السياقات أن تستمر وتتطور، بل وتستمر في التفاعل مع العالم من خلال أنظمة الذكاء الاصطناعي بعد فترة طويلة من رحيل الشخص. قد لا يتم تحميل العقل البشري، لكن

السياق البشري يمكنه ذلك - مما يحول السياق نفسه إلى شكل دائم من المعرفة والذاكرة والهوية.

20

صفحة المصدر 21

9. الاستنتاج SII-GAIR

9 الاستنتاج: في هذه الورقة، نستكشف سياق هندسة السياق، بحجة أنها ليست اختراعا مفاجئا لعصر ولكنها نظام طويل التطور شكله الذكاء التقدمي للآلات. ومن خلال تتبع مراحلها التاريخية LLM ومن خلال تحديد اعتبارات التصميم التي تحكم ممارستها، فإننا نسلط الضوء على كيف يكمن التحدي الأساسي في سد النية البشرية وفهم الآلة في ظل مستويات مختلفة من الإنتروبيا. يشير مسارنا المقترح إلى فك الارتباط البشري تدريجيا عن إدارة السياق الصريح، حيث تتولى الآلات الذكية بشكل متزايد مسؤولية أكبر عن التفسير والتفكير وحتى بناء السياق. وبالنظر إلى المستقبل، "نظرة عين اللهمع اقتراب فهم الآلة من الإدراك البشري وربما تجاوزه، والذي يبلغ ذروته في " المحتملة لنوايانا، فإن أنظمة الذكاء الاصطناعي قد لا تفهمنا فحسب، بل قد تنيرنا وتوسع فهمنا لأنفسنا.

شكر وتقدير نتوجه بخالص الشكر إلى Xiangkun Hu من أمازون على مناقشاته المبكرة. نحن أيضا ممتنون بشدة لشيجي شيا من جامعة شنغهاي جياو تونغ على تعليقاته القيمة.

مراجع

[1] جريجوري د. أبود، وأنيند ك. داي، وبيتر ج. براون، ونايجل ديفيز، ومارك سميث، وبيت ستيجلز. 1999 أ. نحو فهم أفضل للسياق والوعي بالسياق. في وقائع الندوة الدولية الأولى حول الحوسبة المحمولة في كل مكان، الصفحات 304-307. سبرينغر.

[2] جريجوري د. أبود، وأنيند ك. داي، وبيتر ج. براون، ونايجل ديفيز، ومارك سميث، وبيت ستيجلز. 1999 ب. نحو فهم أفضل للسياق والوعي بالسياق. في وقائع الندوة الدولية الأولى حول الحوسبة المحمولة في كل مكان، الصفحات 304-307. [3] غريغوري د. أبود وإليزابيث د. مينات. 2000. رسم الأبحاث الماضية والحاضرة والمستقبلية في مجال الحوسبة في كل مكان. معاملات ACM حول التفاعل بين الكمبيوتر والإنسان، 7 (1) :29-58. [4] كوانجسوب آهن. 2025. هيما: بنية ذاكرة ممتدة مستوحاة من الحصين لمحادثات الذكاء الاصطناعي ذات السياق الطويل. [5] جان

بابتيست ألايراك، جيف دوناهو، بولين لوك، أنطوان ميش، إيان بار، يانا حسون، كاريل لينك، آرثر مينش، كاتي ميليكان، مالكولم رينولدز، رومان رينغ، إليزا روثرفورد، سيركان كابي، تنغدا هان، زيتاو قونغ، وينلونغ هوانغ، ساندر ديليمان، أندرو زيسرمان، كارين سيمونيان، و جواو كاريرا. 2022 أ. فلامنغو: نموذج لغة بصرية للتعلم قليل اللقطات. التقدم في أنظمة معالجة المعلومات العصبية، 35:23716-23736. [6] جان بابتيست ألايراك، جيف دوناهو، بيتر لوك، وآخرون. 2022ب. فلامنغو: نموذج لغة بصرية للتعلم قليل اللقطات. arXiv الطباعة المسبقة arXiv:2204.14198. [7] شون سي أندرسون. 2025. كيفية بناء أنظمة ذكاء اصطناعي متعددة الوكلاء باستخدام هندسة السياق. مدونة Vellum AI. يسلط الضوء على دور هندسة السياق في الأنظمة متعددة الوكلاء، حيث غالبا ما تستخدم تنسيقات البيانات المنظمة مثل JSON لمزامنة مخرجات الوكيل والحفاظ على اتساق السياق.

[8] أنثروبي. 2025 أ. الإعلان عن كلود 4. https://www.anthropic.com/news/claude-4.

[9] أنثروبي. 2025 ب. الوكلاء الفرعيون - وثائق كود كلود. تم الوصول إليه: 20 أغسطس 2025.

[10] الأنثروبيات. 2025. كلود كود. https://github.com/anthropics/claude-code. [11] ماتياس بالدوف، شاهرام دستدار، وفلوريان روزنبرغ. 2007 أ. دراسة استقصائية عن الأنظمة الواعية بالسياق. المجلة الدولية للحوسبة المخصصة والحوسبة في كل مكان، 2 (4) :263-277. [12] ماتياس بالدوف، شاهرام دستدار، وفلوريان روزنبرغ. 2007 ب. دراسة استقصائية عن الأنظمة الواعية بالسياق. المجلة الدولية للحوسبة المخصصة وفي كل مكان، 2 (4) :263-277. [13] تاداس بالتروسايتيس، وشايتانيا أهوجا، ولويس فيليب مورنسي. 2019. التعلم الآلي متعدد الوسائط: مسح وتصنيف. معاملات IEEE حول تحليل الأنماط والذكاء الآلي، 41 (2) :423–443. [14] ريشي بوماساني، ج. هدسون، إي. أديلي، وآخرون. 2021. حول فرص ومخاطر نماذج الأساس. arXiv الطباعة المسبقة arXiv:2108.07258. [15] فلوريان لو برونيك، وسونج دونج، وماتيو رافوت، وألكسندر ألوزن، ونانسي إف تشين، وفنسنت جويج، وألبرتو لومبريراس، ولور سولييه، وباتريك جاليناري. 2024. Locost: نماذج مساحة الدولة للتلخيص التجريدي للوثائق الطويلة.

21

صفحة المصدر 22

المراجع [16] SII-GAIR توم براون، بنيامين مان، نيك رايدر، وآخرون. 2020. نماذج اللغة هي عدد قليل من المتعلمين. التقدم في أنظمة معالجة المعلومات العصبية، 33: 1877-1901. [17]

تيان يي تشي، وشيان لينغ ماو، وتيان لان، وهيان هوانغ. 2024. طريقة تعزيز السياق الهرمي لتحسين مواد الاسترجاع المعززة في الأوراق العلمية. في وقائع مؤتمر ACM SIGKDD الثلاثين حول اكتشاف المعرفة واستخراج البيانات، KDD '24، الصفحة 243-254، نيويورك، نيويورك، الولايات المتحدة الأمريكية. جمعية آلات الحوسبة. [18] لين تشن وينغ شو. 2024. تمثيلات الذاكرة المبنية على المتجهات للبحث الدلالي. في مؤتمر 2024 حول الأساليب التجريبية في معالجة اللغات الطبيعية، الصفحات 1210-1221. [19] فاليري تشين، آلان تشو، سيباستيان تشاو، حسين مزنار، ديفيد سونتاغ، وأميت تالوالكار. 2025. هل تحتاج إلى مساعدة؟ تصميم مساعدين استباقيين للذكاء الاصطناعي للبرمجة. [20] زينجباو تشين، ويوكسوان فو، وتيان يي تشانغ، وتشونيوان ليو، وماوسونغ صن، وجيندونغ وانغ. 2024 أ. A-mem: الذاكرة الفاعلية لوكلاء المواد. ،زيي تشين، وليوشانغ شو، وهونغتينغ تشنغ [21] .arXiv:2502.12110 الطباعة المسبقة arXiv ولوياو تشين، وعمرو طلبة، وليانغ تشاو، وكيبينغ يو، وهايلين فنغ. 2024ب. تطور وآفاق النماذج الأساسية: من نماذج اللغات الكبيرة إلى النماذج الكبيرة متعددة الوسائط. أجهزة الكمبيوتر والمواد والاستمرارية، 80 (2) . [22] يوهونغ داي، وجيانكسون ليان، ويتيان هوانغ، ووي تشانغ، ومينغيانغ تشو، ومينغكي وو، وشينغ شيه، وهاو لياو. 2025. ضاغط سياق التدريب المسبق لنماذج اللغات الكبيرة. arXiv. ضغط السياق الطويل في إصدارات قصيرة مع الحفاظ على تجميد 23] .LLMs] زيهانج داي، تشيلين يانج، وآخرون. 2019. Transformer-xl: نماذج لغة منتبهة تتجاوز سياقا ثابت الطول. في وقائع ACL، الصفحات 2978-2988. [24] إميليا ديفيد. 2024. تطلق الأنثروبي بروتوكول سياق نموذجي لتوحيد تكامل بيانات الذكاء الاصطناعي. فينشربيت. تقارير عن إطلاق بروتوكول السياق النموذجي (MCP)، وهو نظام مصمم لتوفير واجهة موحدة، وبالتالي تخفيف الحاجة إلى محولات مخصصة ومزدوجة في تكامل بيانات الذكاء الاصطناعي.

[25] دبريونج. 2025. كيفية إصلاح السياق الخاص بك. مدونة.

[26] أنيند ك. داي. 2001 أ. فهم واستخدام السياق. الحوسبة الشخصية والشاملة، 5 (1) :4-7. [27] أنيند ك داي. 2001 ب. فهم واستخدام السياق. في وقائع ورشة عمل عام 2001 حول واجهات المستخدم الإدراكية، الصفحات 1-6. [28] ميهاي-دوميترو دوبري، وفلورين بوب، وأندريه-كونستانتين دوبري. 2025. عشر مهام لمعالجة اللغة الطبيعية باستخدام الذكاء الاصطناعي التوليدي. MDPI للعلوم التطبيقية، 15 (16) :9057. تناقش مراجعة 2025 هذه تطبيقات LLM في البرمجة اللغوية العصبية، مع كون تلخيص اللغة الطبيعية إحدى قدرات LLM الأساسية المستخدمة لتعزيز مشاركة السياق. [29] هونغ دو، وسريكانث ثودومو، وراجيش فاسا، وكون موزاكيس. 2025. دراسة استقصائية عن الأنظمة متعددة الوكلاء الواعية بالسياق: التقنيات والتحديات والاتجاهات المستقبلية. [30] برادلي جي إيدلمان، شويلي تشانغ، جيروين شالك، بيتر برونر، جيرنوت مولر بوتز، كونتاي جوان، وبين هي. 2024. واجهات الدماغ والحاسوب غير الغازية: أحدث التطورات والاتجاهات. مراجعات IEEE في الهندسة الطبية الحيوية.

[31] فيسبوك. 2013. Rocksdb: متجر ذو قيمة أساسية ثابتة لتخزين الفلاش وذاكرة الوصول العشوائي. 32] .https://rocksdb.org] لوتشيانو فلوريدي وماسيمو تشيرياتي. 2020. Gpt-3: طبيعته ونطاقه وحدوده وعواقبه. العقول والآلات، 30 (4) :681-694.

[33] ليكس فريدمان. 2025. نسخة لفريق المؤشر: مستقبل البرمجة بالذكاء الاصطناعي. مدونة.

[34] جوجل الجوزاء. 2025. برج الجوزاء. https://github.com/google-gemini/gemini-cli.

[35] سانجاي غيموات وجيف دين. 2014. ليفلدب. https://github.com/google/leveldb.
[36] بن جورتزل وكاسيو بيناتشين. 2021. الذكاء العام الاصطناعي: المفهوم والتطور والآفاق المستقبلية. مجلة الذكاء العام الاصطناعي، 12 (2) :85-109.

[37] ألبرت جو وتري داو. 2024. مامبا: نمذجة التسلسل الزمني الخطي مع مساحات الحالة الانتقائية. [38] أبهيشيك غوبتا. 2025. Mcp: الرابط العالمي لبناء عوامل الذكاء الاصطناعي المعيارية الأكثر ذكاء. معلوماتك. يصف MCP كمعيار مفتوح، مبني على JSON-RPC 2.0، والذي خادم عميل عالمي للأنظمة متعددة الوكلاء لمشاركة مجموعة أدوات مشتركة وتمثيل البيانات. يوفر بروتوكول

22

صفحة المصدر 23

المراجع 39] SII-GAIR] يوجيان هان، شياوتيان لي، شيجي بان، شينغ شيه، وزينغو ليو. 2025. المذكرات: نظام تشغيل لتوليد الذاكرة المعززة في نماذج اللغات الكبيرة. arXiv الطباعة المسبقة ،زيفان هي، وينغكي كاو، وزونجيو تشين، ونيها براكريا، ويتشو صن [40] .arXiv:2505.22101 وجيسون كونغ. 2025. HMT: محول الذاكرة الهرمي لمعالجة لغة السياق الطويلة بكفاءة.

[41] د. ريتشارد هيب. 2000. سكليتي. 42] .https://www.sqlite.org] تايهو هوانج، سوكمين تشو، سويونج جيونج، هويون سونج، سيونج يون هان، وجونج سي بارك. 2024. الخروج: الضغط الاستخراجي المدرك للسياق لتعزيز توليد الاسترجاع المعزز. arXiv. إطار ضغط استخراجي مدرك للسياق لخطوط أنابيب 43] .RAG] رومين إيراني. 2025 أ. الجوزاء-cli. جيثب، تم الوصول إليه: 20-09-2025 .https://github.com/google-gemini/gemini-cli مستودع.

[44] رومين إيراني. 2025 ب. الجوزاء cli التدريب العملي على. تم الوصول إليه: 20-09-2025. [45] رومين إيراني. 2025 ج. سلسلة دروس Gemini cli - الجزء 9: فهم السياق والذاكرة والتفرع التحادثي. تم الوصول إليه: 20-09-2025. [46] غوتييه إيزاكارد وإدوارد جريف. 2022. تقطير من القارئ إلى المسترد للإجابة على الأسئلة. معاملات جمعية اللغويات الحاسوبية، 10: 163-177. المعرفة

[47] أ. جاكوبس. 2025. الانجراف الدلالي وضع الفشل الخفي في مواد العلوم (مذكرة عمل). واقع الانجراف ملاحظات العمل. [48] أندرو جايجل وآخرون. 2021. المدرك: الإدراك العام مع الاهتمام التكراري. المؤتمر الدولي للتعلم الآلي (ICML) . [49] نيكولاس آر جينينغز وكاتيا سيكارا ومايكل وولدريدج. 1998. خريطة طريق للبحث والتطوير للوكلاء. الوكلاء المستقلون والأنظمة متعددة الوكلاء، 1 (1) :7–38. [50] سويونج جيونج، جينهيون بايك، سوكمين تشو، سونج جو هوانج، وجونج سي بارك. 2024. Adaptive-rag: تعلم كيفية تكييف نماذج اللغة الكبيرة المعززة بالاسترجاع من خلال تعقيد الأسئلة. arXiv الطباعة المسبقة 51] .arXiv:2403.14403] ييزو جياو، شا لي، سيزهي تشو، هينغ جي، وجياوي هان. 2024. Text2DB: استخراج المعلومات المدركة للتكامل مع وكلاء نماذج اللغة الكبيرة. في نتائج جمعية اللغويات الحاسوبية: ACL 2024، الصفحات 185-205، بانكوك، تايلاند. جمعية اللغويات الحاسوبية.

[52] زيهاو جين، وانتشنغ وانغ، ويوبو تشين، وشياوزهي لي، وماوسونغ صن، وزييوان تشانغ، وجونشي تانغ. 2024. الذاكرة طويلة المدى: أساس التطور الذاتي للذكاء الاصطناعي. arXiv الطباعة المسبقة جيف جونسون، ماتياس دوزي، وهيرفي جيغو. 2019. بحث التشابه [53] .arXiv:2410.15665 على نطاق ملياري مع وحدات معالجة الرسومات. معاملات IEEE على البيانات الضخمة، 7 (3) :535-547. [54] بوب كابتينز وفلوريان هنتز. 2021. مقارنة المتنبئين بأوقات القراءة الذاتية للجملة: التعقيد النحوي مقابل مقاييس الاحتمالية الانتقالية. مطبوعات OSF الأولية. [55] كاري كوستياينن، ماركو أمبروسين، أبهيشتا أبهيشتا، وبيكا رانتالا. 2012. أمن منصة الهاتف المحمول. في وقائع ندوة ACM السابعة حول أمن المعلومات والكمبيوتر والاتصالات، الصفحات 29-36. [56] نيكولاس د. لين، وإيميليانو ميلوزو، وهونج لو، ودانيال بيبلز، وتنظيم تشودري، وأندرو تي كامبل. 2010. مسح لاستشعار الهاتف المحمول. في مجلة IEEE Communications، المجلد 48، الصفحات 140-150.

[57] لانجرويد. 2025. لانجرويد. 58] .https://github.com/langroid/langroid] باتريك لويس، إيثان بيريز، ألكسندرا بيكتوس، فابيو بتروني، فلاديمير كاربوخين، نامان جويال، أورفاشي خاندلوال، أنجيلا فان، فيشرف تشودري، سينبايار بارتا، وآخرون. 2020. توليد الاسترجاع المعزز لمهام البرمجة اللغوية العصبية كثيفة المعرفة. في التقدم في أنظمة معالجة المعلومات العصبية، المجلد 33، الصفحات 9459-9474. [59] هاو لي وماريا جارسيا. 2024. محول ذاكرة عالي الدقة لتخزين السياق على المدى الطويل. في 2024 التقدم في أنظمة معالجة المعلومات العصبية، الصفحات 900-912. [60] زيو لي، شيشاو سونغ، وتشينيانغ شي. 2025. المذكرات: نظام تشغيل ذاكرة لنظام الذكاء الاصطناعي. arXiv. يوفر تشريح الذاكرة، ووضع العلامات، ورسم الخرائط الهرمية، وقدرات ربط السياق. [61] شينبين ليانغ، جينيو شيانغ، تشاويانغ يو، جيايي تشانغ، سيروي هونغ، شينغ فان،

وشياو تانغ. 2025. Open-manus: إطار عمل مفتوح المصدر لبناء وكلاء الذكاء الاصطناعي العام.

23

صفحة المصدر 24

المراجع SII-GAIR [62] Jifan Lin، Xiaojie Cai، Yang Xiao، Yumin Zhuang، Qishuo Hua، Junfei Wang، وPengfei Liu. 2025. Sii cli: بناء نظام بيئي للذكاء المعرفي للجيل القادم. https://github.com/GAIR-NLP/ SII-CLI. التقرير الفني عن إطار عمل الاستخبارات المعرفية. [63] باريز ليسكافيتس، مكسيم أوشاكوف، شوفيندو روي، مارك كليبانوف، علي اعتماد، وشين لوك. 2024. الضغط الفوري باستخدام ترميز الجملة المدرك للسياق من أجل استنتاج سريع ومحسن للماجستير. [64] بنغفي ليو، وويزهي يوان، وجينلان فو، وزينغباو جيانغ، وهيرواكي هاياشي، وجراهام نيوبيج. 2021. التدريب المسبق والسريع والتنبؤ: مسح منهجي لأساليب التحفيز في معالجة اللغة الطبيعية. arXiv. [65] Zhengwu Liu، Jie Mei، Jianshi Tang، Minpeng Xu، Bin Gao، Kun Wang، Sanchuang Ding، Qi Liu، Qi Qin، Weize Chen، 2025. وآخرون. وحدة فك ترميز عصبية تكيفية تعتمد على الممريستور لواجهات الدماغ والحاسوب. إلكترونيات الطبيعة، الصفحات 1-11. [66] تشي ليو وراج كومار. 2025. Chatdev++: تطوير برامج متعددة الوكلاء قابلة للتطوير مع تضمين السياق الفوري. في وقائع مؤتمر ACM لعام 2025 حول الوكلاء الأذكياء. [67] LlamaIndex. 2024. الاستعلام باستخدام llamaindex. https://docs.llamaindex.ai/en/stable/ Module_guides/querying/. [68] Tengchao Lv، Yupan Huang، Jingye Chen، Yuzhong Zhao، Yilin Jia، Lei Cui، Shuming Ma، Yaoyao Chang، Shaohan Huang، Wenhui Wang، Li Dong، Weiyao Luo، Shaoxiang Wu، Guoxin Wang، Cha Zhang، و Furu Wei. 2024. كوزموس-2.5: نموذج متعلم متعدد الوسائط.

[69] ماوس. 2025. هندسة السياق لوكلاء الذكاء الاصطناعي: دروس من بناء الدليل. مدونة. [70] يانسينغ ماو، يوفي شو، جياكي لي، فانكسو مينغ، هاوتونغ يانغ، زيلونغ تشنغ، شيبوان وانغ، وموهان تشانغ. 2025. الرفع: تحسين فهم السياق الطويل لنماذج اللغات الكبيرة من خلال الضبط الدقيق للمدخلات الطويلة. في أرخايف. ذاكرة الضبط الدقيق والمدخلات الطويلة لمدارس LLM ذات السياق الطويل.

[71] لانس مارتن. 2025. هندسة السياق للوكلاء. مدونة. [72] كارل ماركس. 1845. أطروحات عن فيورباخ. في سي جي آرثر، محرر الأيديولوجية الألمانية. الناشرون الدوليون، نيويورك. العمل الأصلي نشر 1845. [73] عدنان مسعود. 2025. النوافذ ذات السياق الطويل في نماذج اللغات الكبيرة: https://medium.com/@adnanmasood/ long-context-windows-in-large-language-models-applications-in-comprehension-and-code متوفر على واسطة. البرمجية. الفهم والتعليمات تطبيقات في

[74] Lingrui Mei, Jiayu Yao, et al. 2025. مسح لهندسة السياق لنماذج اللغات الكبيرة. arXiv:2507.13334. [75] Y. Meng، Z. Bing، X. Yao، et al. الطباعة المسبقة arXiv

2025. الحفاظ على المعرفة والجمع بينها في التعلم المعزز الآلي مدى الحياة. طبيعة آلة الذكاء، 7: 256-269. [76] إميليانو ميلوزو، ونيكولاس د. لين، وكريستوف فودور، ورونالد بيترسون، وهونج لو، وميركو موسوليسي، وشين بي. أيزنمان، وشياو تشنغ، وأندرو تي كامبل. 2008. الاستشعار يلتقي بالشبكات الاجتماعية المتنقلة: تصميم وتنفيذ وتقييم تطبيق cenceme. في وقائع مؤتمر ACM السادس حول أنظمة الاستشعار الشبكية المدمجة، الصفحات 337-350.

[77] فارون موهان. 2025. مناقشة ركوب الأمواج. مدونة. [78] ميريديث رينجل موريس، جاشا سوهل ديكستين، نوح فيدل، تريس واركنتين، آلان دافو، ألكسندرا فاوست، كليمنت فارابت، وشين ليغ. 2023. مستويات الذكاء الاصطناعي لتفعيل التقدم على الطريق نحو الذكاء الاصطناعي. arXiv الطباعة المسبقة arXiv:2311.02462.

[79] أوبن إيه آي. 2024. التقرير الفني لـGpt-4.

[80] آدي عثماني. 2025. نصائح هندسة السياق. مدونة. [81] جيف ز. بان، سيمون رازنيفسكي، جان كريستوف كالو، سنيها سينجانيا، جياويان تشين، ستيفان ديتز، هاجيرا جابين، جانا أوميليانينكو، وين تشانغ، ماتيو ليساندريني، روسا بيسواس، جيرارد دي ميلو، أنجيلا بونيفاتي، إدليرا فاكاج، ماورو دراغوني، وداميان غراو. 2023. النماذج اللغوية الكبيرة والرسوم البيانية المعرفية: الفرص والتحديات. [82] تشووشي بان، تشيانهوي وو، هويكيانغ جيانغ، زوفانغ لو، هاو تشنغ، دونغ شنغ لي، يو تشينغ يانغ، تشين يو لين، إتش. فيكي تشاو، ليلي تشيو، وجيان فينغ جاو. 2025. حول بناء الذاكرة واسترجاعها لوكلاء المحادثة الشخصية.

24

صفحة المصدر 25

المراجع 83] SII-GAIR] آراف باتيل وبريا سينغ. 2025. هياكل الذاكرة ذات الطبقات لوكلاء الذكاء الاصطناعي التكيفي. في المؤتمر الدولي للتعلم الآلي لعام 2025، الصفحات من 678 إلى 689.

[84] زيليانغ بينغ، وينهوي وانغ، لي دونغ، يارو هاو، شاوهان هوانغ، شومينغ ما، وفورو وي. 2023.كوزموس-2: ترسيخ نماذج اللغات الكبيرة متعددة الوسائط للعالم. [85] ليون بيرديجاو. 2025. هندسة السياق: تصميم الوعي الظرفي لأنظمة الذكاء الاصطناعي. واسطة. يناقش وضع علامات على رسائل الدردشة باستخدام البيانات الوصفية لتمييز السياق. [86] تاتيانا بتروفا، بوريس بليزنيوكوف، ألكسندر بوزيكوف، ورادو ستيت. 2025. من الويب الدلالي والماس إلى الذكاء الاصطناعي الوكيل: سرد موحد لشبكة الوكلاء.

[87] فيلشميد. 2025. ورقة الغش في Google Gemini CLI. تم الوصول إليه: 2025-09-20.

[88] ساهانا فيجايا براساد. 2025. كيف يقدم برنامج coderabbit مراجعات دقيقة لأكواد الذكاء الاصطناعي على قواعد تعليمات برمجية ضخمة. مدونة. [89] جيني بريس، إيفون روجرز، هيلين شارب، ديفيد بينيون، سايمون هولاند، وتوم كاري. 1994. التفاعل بين الإنسان والحاسوب. Addison-Wesley Longman Ltd. [90] Chen Qian، Wei Liu، Hongzhang Liu، Nuo Chen، Yufan Dang، Jiahao Li، Cheng Yang، Weize Chen، Yusheng Su، Xin Cong،

وكلاء التواصل :Juyuan Xu، Dahai Li، Zhiyuan Liu، وMaosong Sun. 2024. Chatdev لتطوير البرمجيات. [91] يوجيا تشين، ويينينغ يي، وجونجي فانغ، وهاومينغ وانغ، وشيهاو ليانغ، وآخرون. 2025. UI-TARS: رائدة في التفاعل الآلي لواجهة المستخدم الرسومية مع الوكلاء الأصليين. arXiv الطباعة المسبقة arXiv:2501.12326.

[93] أليك رادفورد، جونغ ووك كيم، كريس هالاسي، أديتيا راميش، غابرييل جوه، ساندهيني أغاروال، جيريش ساستري، أماندا أسكيل، باميلا ميشكين، جاك كلارك، جريتشن كروجر، وإيليا سوتسكيفر. 2021. تعلم النماذج المرئية القابلة للتحويل من الإشراف على اللغة الطبيعية. وقائع المؤتمر الدولي الثامن والثلاثين للتعلم الآلي، الصفحات 8748-8763. [92] ماركوس إن راب وتشارلز ستاتس. 2022. الاهتمام الذاتي لا يحتاج إلى ذاكرة (94] .(n2] أناند راج. 2025. Agentic ai وبروتوكول السياق النموذجي: عصر جديد من الوكلاء المستقلين. واسطة. يناقش كيف يمكن MCP Agentic من توسيع ذاكرته عن طريق استرداد المعلومات من قواعد المعرفة الخارجية، والتي يتم تنفيذها AI غالبا كقواعد بيانات متجهة تخزن السياق كمتجهات دلالية. [95] ستيوارت ريفز. 2012. تصور الحوسبة في كل مكان. في وقائع مؤتمر SIGCHI حول العوامل البشرية في أنظمة الحوسبة، الصفحات 1573-1582.

[96] أبحاث لانجشين. 2025. هندسة السياق. مدونة. [97] لاريا رينولدز وكايل ماكدونيل. 2021. البرمجة السريعة لنماذج اللغات الكبيرة: ما وراء نموذج اللقطات القليلة. arXiv الطباعة المسبقة مونكيونغ ريو، تشيه-وي هسو، ينلام تشاو، محمد قوامزاده، وكريغ [98] .arXiv:2102.07350 بوتيلييه. 2025. توليد الحوار التركيبي لاستنباط المحادثة التفاعلية والتوصية (99] . (icer] بارول ساهو. 2025. سرب Openai: دليل عملي للأنظمة متعددة الوكلاء. تحليلات فيدهيا. يقدم إطار عمل " لتمكين JSON الذي يستخدم هياكل ،OpenAI Swarmمتغيرات السياق"لتنظيم الوظائف و الوكلاء من مشاركة المعلومات وتنسيق المهام باستخدام تنسيق بيانات ثابت. [100] دانيال سالبر، وأنيند ك داي، وغريغوري د أبود. 1999. مجموعة أدوات السياق: المساعدة في تطوير التطبيقات التي تدعم السياق. في وقائع مؤتمر SIGCHI حول العوامل البشرية في أنظمة الحوسبة، الصفحات 441-434. ايه سي ام. [101] علي رضا سالمي، ميهير بارمار، بالاش جويال، يوين سونغ، جينسونغ يون، حامد زماني، حميد بالانجي، وتوماس فيستر. 2025. نظام بلاك بورد متعدد الوكلاء قائم على لاكتشاف المعلومات في علم البيانات. [102] ماهاديف ساتيانارايانان. 2001. الحوسبة LLM المنتشرة: الرؤية والتحديات. في الاتصالات الشخصية لمعهد مهندسي الكهرباء والإلكترونيات (IEEE)، 2023. المجلد 8، الصفحات 10-17. [103] تيمو شيك، جين دويفيدي-يو، وآخرون. الطباعة المسبقة arXiv .يمكن لنماذج اللغة أن تعلم نفسها كيفية استخدام الأدوات :Toolformer

بيل ن. شيليت ومايكل إم ثيمر. 1994. نشر معلومات الخريطة [104] .arXiv:2302.04761
النشطة على الأجهزة المضيفة المتنقلة. في شبكة IEEE، المجلد 8، الصفحات 22-32.

[105] شارك دروبيو. 2025. مشاركة. https://github.com/ShareDropio/sharedrop.

25

المراجع 106] SII-GAIR] بن شنايدرمان. 1987. تصميم واجهة المستخدم: استراتيجيات التفاعل الفعال بين الإنسان والحاسوب. أديسون ويسلي. [107] ديفيد سيلفر، وأجا هوانغ، وكريس جي ماديسون، وآخرون. 2016. إتقان لعبة go باستخدام الشبكات العصبية العميقة والبحث عن الأشجار. طبيعة، 529 (7587) :484-489. [108] جون سميث ووي تشانغ. 2025. ملخص يومي للمحادثات الطويلة في مادة العلوم. في وقائع مؤتمر 2025 حول معالجة اللغات الطبيعية، الصفحات 101-112. [109] Stackademic. 2025. بنية الذاكرة ذات الطبقات لعملاء الذكاء الاصطناعي الأذكياء: من السياق السريع إلى المعرفة العميقة. منشور المدونة، Stackademic، تم نشره منذ شهرين. [110] هاوران صن وشاونينج تسنغ. 2025. الذاكرة الهرمية للتفكير طويل الأمد عالي الكفاءة في وكلاء العلوم. [111] جي صن، تيانيو تشانغ، هوتشنغ جيانغ، كيكسين هوانغ، تشي لو، جونكانغ وو، جيانكان وو، آن تشانغ، وشيانغ وانغ. 2024. تعمل نماذج اللغات الكبيرة على تمكين التقييم الشخصي في المزاد.

[112] Ruiming Tang، وChenxu Zhu، وBo Chen، وWeipeng Zhang، وMenghui Zhu، وXinyi Dai، وHuifeng Guo. 2025.Llm4tag: نظام وضع العلامات التلقائي لاسترجاع المعلومات عبر نماذج اللغات الكبيرة. arXiv. يستخدم إنشاء العلامات المستندة إلى الرسم البياني والمعززة بالمعرفة باستخدام LLMs. [113] شين تانغ، وهاو شين، وسيوان تشاو، ونا لي، وجيا ليو. 2023. واجهات مرنة بين الدماغ والحاسوب. إلكترونيات الطبيعة، 6 (2) :109-118.

[114] الفريق الأنثروبي. 2025 أ. هندسة السياق الفعالة لوكلاء الذكاء الاصطناعي. مدونة.

[115] الفريق الأنثروبي. 2025 ب. كيف قمنا ببناء نظام البحث متعدد الوكلاء لدينا. مدونة.

[116] فريق AutoGPT. 2025 ج. Autogpt. https://github.com/Significant-Gravitas/AutoGPT.

[117] فريق DataCamp. 2025 د. أفضل 7 قواعد بيانات متجهة في عام 2025. مدونة DataCamp. يسرد أهم قواعد بيانات المتجهات لعام 2025، والتي تعد البنية التحتية الأساسية لتمثيل السياق كمتجهات دلالية وتمكين الاسترجاع الفعال في أنظمة الذكاء الاصطناعي. [118] فريق ديسكوب. 2025هـ. ما هو بروتوكول السياق

النموذجي (mcp) وكيف يعمل. مدونة ديسكوب. يشرح كيف تقوم MCP بتوحيد اتصال الأدوات جهازلأنظمة الذكاء الاصطناعي من خلال تحديد مجموعة متسقة من المواصفات، لتكون بمثابة " " للذكاء الاصطناعي وإنشاء تمثيل مشترك. [119] فريق ليتا. 2024. ليتاتحكم عن بعد عالمي مستودع جيثب. https://github.com/letta-ai/letta. (سابقا memgpt).

[120] فريق OpenSII. 2025f. اوبنسي. https://www.opensii.ai.

[121] فريق OpenSII. 2025 جرام. اوبنسي. 122] https://www.opensii.ai/cli/docs.] فريق تونغي للأبحاث العميقة. 2025 ح. تونغي-البحث العميق. https://github.com/Alibaba-NLP/ معالجة اللغة الطبيعية في روبوتات الدردشة Verloop.io. 2025i. فريق [123] DeepResearch. 2025. مدونة Verloop.io. يؤكد على كيفية تحقيق روبوتات الدردشة الخاصة بالبرمجة اللغوية " من خلال الاحتفاظ بالسياق وفهمه، وهو ما يمكن تحقيقهالمشاركة السياقيةالعصبية لعام 2025 " من خلال تبادل الملخصات التي يمكن قراءتها بواسطة الإنسان. [124] هوي تان تاي، وكيم هونغ لي، ونجان لو ثوي نجوين. 2023. Formerleaf: محول رؤية فعال للكشف عن أمراض أوراق الكسافا. أجهزة الكمبيوتر والإلكترونيات في الزراعة، 204:107518. [125] أشيش فاسواني، نعوم شازير، نيكي بارمار، جاكوب أوسزكوريت، ليون جونز، إيدان إن. جوميز، لوكاس كايزر، وإيليا بولوسوخين. 2017. الاهتمام هو كل ما تحتاجه. في التقدم في أنظمة معالجة المعلومات العصبية، الصفحات 5998-6008. [126] فاي وانغ، يووين تشنغ، تشين لي، جينغي وو، بينجفي لي، ولوكسيا تشانغ. 2024 أ. Chatschema: خط أنابيب لاستخراج المعلومات المنظمة باستخدام نماذج كبيرة متعددة الوسائط تعتمد على المخطط. [127] Peng Wang، Shuai Bai، Sinan Tan، Shijie Wang، Zhihao Fan، Jinze Bai، Keqin Chen، Xuejing Liu، Jialin Wang، Wenbin Ge، Yang Fan، Kai Dang، Mengfei Du، Xuancheng Ren، Rui Men، Dayiheng Liu، Chang Zhou، Jingren Zhou، و Junyang Lin. 2024ب. Qwen2-vl: تعزيز تصور نموذج لغة الرؤية للعالم بأي دقة. [128] جيسون وي وآخرون. 2022. سلسلة الأفكار المحفزة تثير التفكير في نماذج اللغة الكبيرة. التقدم في أنظمة معالجة المعلومات العصبية، 24824:35-24837.

26

صفحة المصدر 27

المراجع SII-GAIR

[129] مارك وايزر. 1991. الكمبيوتر للقرن الحادي والعشرين. ساينتفيك أمريكان، 265 (3) :94-104. [130] زيهاو وين، شنغ ليانغ، ياشيونغ وو، يونغيو تشانغ، ويونغ ليو. 2025. استخراج معلومات فعالة وفعالة واعية بالمخطط باستخدام نماذج اللغة الكبيرة الموجودة على الجهاز. [131] ريبيكا ويستهاوسر، وفريدريك بيرنز، وولفغانغ مينكر، وسيباستيان زيبف. 2025. كيم: تطوير وتقييم الذاكرة المعرفية. arXiv. نظام العلامات المتكامل والتصفية السياقية لاستدعاء الذاكرة. [132] دونجروي وو، وباو ليانج لو، وبن هو، وتشيجانج زينج. 2023. واجهات الدماغ والكمبيوتر العاطفية IEEE، 111 (10) :1314-1332. [133] Xixi Wu، Kuan Li، برنامج تعليمي. وقائع :(abcis) Yida Zhao، Liwen Zhang، Litu Ou، Huifeng Yin، Zhongwang Zhang، Yong Jiang، Pengjun Xie، Fei Huang، Minhao Cheng، Shuai Wang، Hong Cheng، و Jingren Zhou. 2025. السيرة الذاتية: إطلاق العنان لذكاء البحث طويل المدى من خلال تلخيص السياق.

[134] يوهواي وو، ماركوس إن راب، ديلسلي هتشينز، وكريستيان سيجيدي. 2022. تحفيظ المحولات. [135] يانغ شياو، موهان جيانغ، جي صن، كيو لي، جيفان لين، يومين تشوانغ، جي تسنغ،

شيجي شيا، تشيشو هوا، شيوفنغ لي، شياو جيه كاي، تونغيو وانغ، يو تشانغ، ليمينغ ليو، شيا وو، جين لونغ هو، يوان تشنغ، وينجي لي، شيانغ وانغ، ديكوان وانغ، وبنغفي ليو. 2025. ليمي: الأقل هو الأفضل بالنسبة للوكالة. [136] يو شينغ، وتاو يانغ، وييجياشون تشي، ومينغغو وي، ويو تشينغ، وهونغوي شين. 2025. آليات الذاكرة المنظمة لتمثيل السياق المستقر في نماذج اللغة الكبيرة.

[137] كيلين شو، وييتشن تشانغ، ويوجيا باي، وشيانغ نينغ لين، وجينشاو تشين، وكووك في لو، وديني تشو. 2025. تعلم كيفية تضافر الذاكرة والتفكير من أجل عوامل فعالة طويلة الأفق. arXiv الطباعة المسبقة 138] .arXiv:2506.15841] وينلي يانغ، يوشين وي، هانيو وي، يانيو تشين، غوان هوانغ، شيانغ لي، رينجي لي، نايمنغ ياو، شينيي وانغ، شياوتونغ غو، وآخرون. 2023. مسح حول الذكاء الاصطناعي القابل للتفسير: من جوانب المناهج والقيود والتطبيقات. الأنظمة الذكية المتمحورة حول الإنسان، 3 (3) :161-188. [139] شين ياو وآخرون. 2022. رد الفعل: التآزر بين الاستدلال والتصرف في نماذج اللغة. arXiv الطباعة المسبقة 140] .arXiv:2210.03629] شونيو ياو وديان يو وجيفري تشاو. 2025. شجرة الأفكار: حل متعمد للمشكلات باستخدام نماذج لغوية كبيرة. في 141] .ICLR] شونيو ياو، وجيفري تشاو، وديان يو، ونان دو، وإسحاق شافران، وكارثيك ناراسيمهان، ويوان كاو. 2023. رد الفعل: التآزر بين الاستدلال والتصرف في نماذج اللغة. [142] ميشيهيرو ياسوناجا، أرمين أغاجانيان، ويجيا شي، ريتش جيمس، جور ليسكوفيك، بيرسي ليانغ، مايك لويس، لوك زيتلموير، ووين تاو ييه. 2023. نمذجة اللغة متعددة الوسائط المعززة بالاسترجاع. [143] ليومانشان يي، شياو جيه كاي، شينكاي وانغ، جونفي وانغ، شيانغكون هو، جيادي سو، يانغ نان، سيهان وانغ، بوهان تشانغ، شياوز فان، جينبين لو، يوكسيانغ تشنغ، تيانزي شو، دايوان فو، يونزي وو، بينجروي لو، زينجزي وانغ، يوي تشين، تشن هوانغ، يان ما، زولين هو، هاويانغ زو، تيانتيان مي، وييكسين يي، وإيثان تشيرن، وبنغفي ليو. 2025 أ. التفاعل كذكاء: بحث عميق مع الشراكة بين الإنسان والذكاء الاصطناعي. [144] يي يي. 2025. محرك ذاكرة المهام: الذاكرة المكانية لوكلاء العلوم القويين متعددي الخطوات. arXiv الطباعة المسبقة 145] .arXiv:2505.19436] زيفان يي، وكيجينغ شيا، ويونغغان فو، وشين دونغ، وجيهون هونغ، وشيانغتشي يوان، وشيزهي دياو، وجان كاوتز، وبافلو مولتشانوف، وييننغيان سيلين لين. 2025 ب. Longmamba: تعزيز قدرات السياق الطويل للمامبا من خلال توسيع مجال الاستقبال بدون تدريب.

[146] سيونغهيون يون وآخرون. 2025. Memory-r1: تعلم تعزيز الذاكرة لنماذج اللغات الكبيرة. مدونة. [147] عاطفة زراب زاده، ونيلوفر منتظري، وعايدة ذو الفقاري. 2024. مسح شامل حول الأنظمة متعددة الوكلاء الواعية بالسياق: التقنيات والتطبيقات والتحديات والاتجاهات المستقبلية. كور، عبس/2402.01968. يناقش استطلاع عام 2024 التحديات في الأنظمة متعددة الوكلاء

المدركة للسياق (CA-MAS)، حيث يتطلب عدم التجانس غالبا آليات تكيفية لاكتساب السياق وتجريده. [148] جويبين تشانغ، موكسين فو، غوانتشنغ وان، مياو يو، كون وانغ، وشويشينغ يان. 2025. ذاكرة G: تتبع الذاكرة الهرمية للأنظمة متعددة الوكلاء. arXiv الطباعة المسبقة arXiv:2506.07398. [149] روي تشاو وسون كيم. 2025. محول الذاكرة الهرمي للذكاء الاصطناعي المدرك للسياق. في مؤتمر 2025 حول معالجة المعلومات العصبية، الصفحات 1123-1135.

27

صفحة المصدر 28

المراجع SII-GAIR [150] Siyun Zhao، Yuqing Yang، Zilong Wang، Zhiyuan He، وما بعده: استطلاع شامل حول (rag) الجيل المعزز للاسترجاع .2024 Lili Qiuو، Luna K Qiu، كيفية جعل موادك الدراسية تستخدم البيانات الخارجية بشكل أكثر حكمة. arXiv الطباعة المسبقة arXiv:2409.14924. [151] ،جونهاو تشنغ، وشيدي كاي، وكيوكي لي، ودوجين تشانغ، وزونغزي لي وينغيينغ تشانغ، ولو سونغ، وتشيانلي ما. 2025. Lifelongagentbench: تقييم وكلاء ماجستير العلوم باعتبارهم متعلمين مدى الحياة.

28